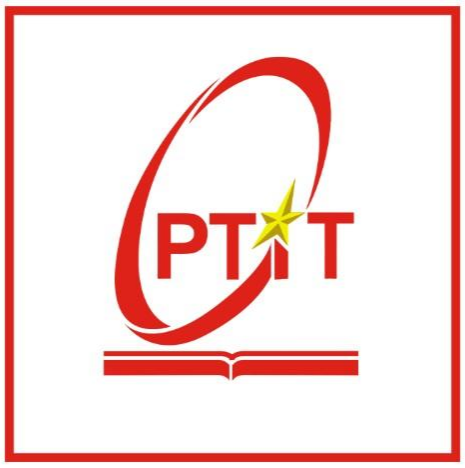
HỌC VIỆN CÔNG NGHỆ BƯU CHÍNH VIỄN THÔNG
KHOA CÔNG NGHỆ THÔNG TIN II



TIỂU LUẬN

Học phần Hệ cơ sở dữ liệu đa phương tiện

ĐỀ TÀI 8:

XÂY DỰNG HỆ THỐNG TRUY XUẤT VĂN BẢN TIẾNG VIỆT SỬ DỤNG TF-IDF

Giảng viên: Ths. Nguyễn Ngọc Duy
Nhóm thực hiện: Nhóm 7
Thành viên:

1. Lê Đình Bảo N23DCCN141
2. Đặng Văn Hiệp N23DCCN155
3. Nguyễn Ngọc Quốc Huy N23DCCN162

TP. Hồ Chí Minh – 2026

MỤC LỤC

LỜI MỞ ĐẦU 4
PHÂN CÔNG CÔNG VIỆC 5
CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI 6
1.1. Bối cảnh và bài toán 6
1.2. Mục tiêu và yêu cầu thực hiện 6
1.3. Đối tượng nghiên cứu và phạm vi 6
CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ CÔNG NGHỆ SỬ DỤNG 7
2.1. Truy xuất thông tin và chỉ mục đảo 7
2.2. Tách từ tiếng Việt bằng Maximum Matching 7
2.3. Stopword và cấu hình lọc C1–C4 7
2.4. Mô hình không gian vector và TF-IDF 7
2.5. Cosine similarity và phân rã đóng góp 8
2.6. Giá trị phân biệt từ TDV (Salton) 8
2.7. Các chỉ số đánh giá chất lượng truy xuất 8
2.8. Ngôn ngữ lập trình và kiến trúc giao tiếp 9
2.9. Thư viện tính toán và biểu diễn ma trận thưa 10
2.10. Cơ chế lưu trữ dữ liệu cục bộ 10
CHƯƠNG 3. PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG 12
3.1. Tác nhân và yêu cầu chức năng 12
3.2. Yêu cầu phi chức năng và ranh giới hệ thống 12
3.3. Thiết kế kiến trúc tổng thể 12
3.4. Thiết kế đối tượng và liên kết dữ liệu 13
3.5. Thiết kế luồng tìm kiếm và xử lý ngoại lệ 14
3.6. Thiết kế bố cục và tương tác giao diện 14
CHƯƠNG 4. HIỆN THỰC HỆ THỐNG 15
4.1. Tổ chức mã nguồn và các mô đun 15
4.2. Hiện thực xử lý ngôn ngữ 15
4.3. Hiện thực TF-IDF chỉ mục đảo và giải thích 16
4.4. Hiện thực TDV và cơ chế dự phòng 17
4.5. Hiện thực lưu trữ và kiểm tra phiên bản 19
4.6. API và hiện thực giao diện 19
CHƯƠNG 5. VẬN HÀNH HỆ THỐNG VÀ ĐÁNH GIÁ 21

5.1. Môi trường và chuẩn bị dữ liệu 21
5.2. Tìm kiếm văn bản với dữ liệu thực 22
5.3. Giải thích điểm Cosine của một kết quả 23
5.4. Vận hành chức năng tách từ 24
5.5. Vận hành lọc từ dừng và guard 25
5.6. Cơ chế dự phòng và các trường hợp biên 26
5.7. Thực nghiệm và phân tích kết quả 27
5.7.1. Chất lượng phân đoạn từ 27
5.7.2. Dung lượng chỉ mục và phân bố TDV 27
5.7.3. Độ trễ truy vấn 29
5.7.4. Chất lượng truy xuất và phân tích lĩnh vực 30
5.7.5. Đối chứng cấu trúc tra cứu 33
5.7.6. Kiểm tra tính nhất quán và phạm vi đánh giá 33
CHƯƠNG 6. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN 34
6.1. Kết quả đạt được 34
6.2. Hạn chế 34
6.3. Hướng phát triển 35
TÀI LIỆU THAM KHẢO 36
PHỤ LỤC A. MỘT SỐ TRƯỜNG HỢP GÁN NHÃN LIÊN QUAN 37
PHỤ LỤC B. MỘT SỐ TRƯỜNG HỢP PHÂN ĐOẠN TỪ 38
PHỤ LỤC C. DANH MỤC 20 TRUY VẤN 39

LỜI MỞ ĐẦU

Truy xuất thông tin giúp tìm các tài liệu phù hợp với nhu cầu của người dùng trong một kho văn bản. Đề tài thuộc chủ đề 8 của học phần Hệ cơ sở dữ liệu đa phương tiện triển khai hệ thống tìm kiếm toàn văn tiếng Việt trên 2.500 bài báo thuộc 10 lĩnh vực. Tiểu luận trình bày cơ sở lý thuyết, cách cài đặt và kết quả so sánh các chiến lược lọc từ dừng.

Điểm đặc thù của tiếng Việt là đơn vị viết tách nhau bằng dấu cách là âm tiết, trong khi đơn vị mang nghĩa lại là từ đơn hoặc từ ghép nhiều âm tiết. Vì vậy trước khi lập chỉ mục, hệ thống phải phân đoạn văn bản thành từ có nghĩa: nhiệm vụ tách từ, được giải bằng thuật toán so khớp cực đại Maximum Matching trên cấu trúc Trie với từ điển chuẩn hóa Viet74K, kèm chiến lược so khớp hai chiều BiMM.

Tiếp theo, các từ ít có khả năng phân biệt nội dung (stopword) được loại theo hai tầng: tầng hư từ theo chức năng ngữ pháp và tầng giá trị phân biệt từ TDV (Term Discrimination Value) của Salton để chọn stoplist theo miền. Văn bản và truy vấn được biểu diễn bằng trọng số TF-IDF trong mô hình không gian vector, do đó độ tương đồng giữa truy vấn và văn bản được đo bằng Cosine similarity trên chỉ mục đảo.

Tiểu luận được tổ chức theo ba mạch nội dung bắt buộc của đề tài: (i) cơ sở lý thuyết — tách từ tiếng Việt, stopword, TF-IDF, cosine, TDV và các độ đo đánh giá; (ii) cài đặt giải thuật và chương trình — kiến trúc, cấu trúc dữ liệu, bốn cấu hình C1–C4, các bảo vệ hành vi; (iii) thực nghiệm và đánh giá — chất lượng truy xuất trên quy tắc gán nhãn có kiểm soát, benchmark độ trễ, dung lượng chỉ mục, ablation theo bốn cấu hình, kiểm định tách từ trên tập chuẩn vàng cùng phân tích lỗi.

Tiểu luận được tổ chức thành sáu chương: giới thiệu đề tài; cơ sở lý thuyết và công nghệ; phân tích thiết kế; hiện thực hệ thống; vận hành và đánh giá; kết luận và hướng phát triển. Các ảnh giao diện ở Chương 5 được chụp khi ứng dụng kết nối backend và đã có dữ liệu đầu vào, kết quả xử lý.

PHÂN CÔNG CÔNG VIỆC

Nhóm phân chia công việc thành ba mảng: xử lý ngôn ngữ, truy xuất và đánh giá, giao diện và tích hợp.

Bảng PC.1. Phân công vai trò và trách nhiệm của các thành viên

Thành viên / MSSV	**Vai trò**	**Công việc được phân công**
Lê Đình Bảo N23DCCN141	M1 Xử lý ngôn ngữ	Chuẩn hóa văn bản và từ điển; cấu trúc Trie; FMM/BMM/BiMM; lọc từ dừng tầng 1 và guard; đánh giá tách từ, rà soát nhãn; tổng hợp và hoàn thiện tiểu luận.
Đặng Văn Hiệp N23DCCN155	M2 Truy xuất và đánh giá	Chuẩn bị corpus, truy vấn và nhãn relevance; TF-IDF, chỉ mục đảo, Cosine và explain; TDV; thực nghiệm so sánh C1–C4, đo chất lượng và hiệu năng; nội dung tiểu luận về truy xuất và kết quả.
Nguyễn Ngọc Quốc Huy N23DCCN162	M3 Giao diện và tích hợp	Kiến trúc và giao tiếp giữa các mô đun; giao diện và trực quan hóa; tích hợp, kiểm tra luồng sử dụng, đóng gói và hướng dẫn vận hành.

CHƯƠNG 1. GIỚI THIỆU ĐỀ TÀI

1.1. Bối cảnh và bài toán

Hệ thống nhận một câu truy vấn tiếng Việt và trả về các văn bản liên quan trong kho dữ liệu. Chuỗi xử lý gồm chuẩn hóa, tách từ, lọc từ dừng, biểu diễn TF-IDF, tính Cosine và xếp hạng. Đề tài đồng thời đánh giá ảnh hưởng của chiến lược lọc từ dừng đến chất lượng truy xuất, thời gian truy vấn và dung lượng chỉ mục.

1.2. Mục tiêu và yêu cầu thực hiện

Bảng 1.1 đối chiếu năm yêu cầu chính của chủ đề 8 với các chức năng đã cài đặt.

Bảng 1.1. Đối chiếu yêu cầu đề tài với phạm vi thực hiện

Yêu cầu đề tài	**Cài đặt trong dự án**
Tách từ tiếng Việt	FMM/BMM/BiMM trên Trie; từ điển 69.858 mục; trace; đánh giá span trên 150 câu
Loại từ dừng	Tầng 1 ngữ pháp và guard; tầng 2 TDV; đối chứng C1–C4
TF-IDF	TF = 1+ln(f); IDF làm mượt; chuẩn hóa L2; ma trận thưa CSR
Cosine	Lấy ứng viên từ posting list; giải thích điểm theo từng thuật ngữ
Đánh giá	P/R/F1/NDCG@10, MAP toàn ranking; 20 truy vấn và 669 cặp nhãn 0/1/2

1.3. Đối tượng nghiên cứu và phạm vi

Đối tượng nghiên cứu là quy trình truy xuất văn bản tiếng Việt theo mô hình không gian vector, tập trung vào tương tác giữa phân đoạn từ, lọc từ dừng, trọng số TF-IDF và xếp hạng Cosine. Đơn vị dữ liệu là bài báo và cặp truy vấn–tài liệu; đối tượng đánh giá bổ sung là ranh giới từ trên câu tiếng Việt.

Hệ thống tìm kiếm chạy cục bộ trên corpus 2.500 bài thuộc 10 lĩnh vực (Chính trị xã hội, đời sống, khoa học, kinh doanh, pháp luật, sức khỏe, thế giới, thể thao, văn hóa, vi tính). Chỉ mục được dựng từ dữ liệu và tài nguyên của dự án; quá trình truy vấn không phụ thuộc dịch vụ bên ngoài. Bộ đánh giá gồm 20 truy vấn, 669 cặp truy vấn–tài liệu được gán mức liên quan và 150 câu có nhãn phân đoạn tham chiếu. Phạm vi thực nghiệm tập trung vào chất lượng truy xuất, chất lượng tách từ, thời gian truy vấn và dung lượng chỉ mục.

Phạm vi cài đặt gồm tìm kiếm cục bộ, giải thích điểm, mô phỏng tách từ, lọc từ dừng và công cụ đánh giá. Dự án không triển khai thu thập tin trực tuyến liên tục, suy luận ngữ nghĩa bằng mô hình ngôn ngữ hay hệ thống nhiều người dùng có phân quyền. Các giới hạn này giúp phân biệt kết quả thực hiện đề tài với một dịch vụ tìm kiếm vận hành ở quy mô lớn.

CHƯƠNG 2. CƠ SỞ LÝ THUYẾT VÀ CÔNG NGHỆ SỬ DỤNG

2.1. Truy xuất thông tin và chỉ mục đảo

Một hệ thống truy xuất thông tin gồm tập tài liệu, truy vấn, chỉ mục và tiêu chí liên quan. Chỉ mục đảo ánh xạ mỗi thuật ngữ tới danh sách tài liệu chứa thuật ngữ đó (posting list) [1]. Khi truy vấn, hệ thống chỉ tính điểm cho các ứng viên có thuật ngữ chung. Bản cài đặt dùng ma trận thưa CSR để biểu diễn trọng số TF-IDF, kết hợp posting list để lấy ứng viên.

2.2. Tách từ tiếng Việt bằng Maximum Matching

Một từ tiếng Việt có thể gồm nhiều âm tiết viết cách nhau. Maximum Matching là một hướng tiếp cận tách từ tiếng Việt [2]. Bản hiện thực chọn chuỗi âm tiết dài nhất có trong từ điển tại vị trí đang xét; cửa sổ tối đa bằng độ dài mục dài nhất của từ điển.

FMM quét từ trái sang phải, BMM quét từ phải sang trái. Bản hiện thực BiMM của nhóm chạy cả hai chiều rồi chọn phân đoạn theo thứ tự tiêu chí sau:

- Ưu tiên phân đoạn có ít token hơn;
- Nếu bằng nhau, ưu tiên ít token đơn âm tiết hơn;
- Nếu vẫn bằng nhau, ưu tiên ít token ngoài từ điển hơn;
- Nếu cả ba tiêu chí bằng nhau, chọn kết quả BMM.

Chất lượng tách từ được đánh giá bằng khớp span: một từ chỉ đúng khi cả đầu và cuối span đều khớp nhãn người. Chỉ số Precision = span khớp / span dự đoán; Recall = span khớp / span gold; F1 = trung bình điều hòa của hai số.

2.3. Stopword và cấu hình lọc C1–C4

Từ dừng là các từ được cân nhắc loại bỏ để giảm nhiễu hoặc dung lượng biểu diễn. Tiểu luận so sánh hai cách chọn: danh sách theo chức năng ngữ pháp và danh sách dựa trên giá trị phân biệt từ TDV. Danh sách bảo vệ giữ các dấu hiệu quan trọng như từ phủ định. Bốn cấu hình dùng cùng corpus và thuật toán tách từ, chỉ thay đổi chính sách lọc:

Bảng 2.1. Bốn cấu hình lọc từ dừng C1 đến C4

Cấu hình	Nội dung lọc stopword
C1	Không lọc — baseline, giữ mọi từ sau khi tách.
C2	Danh sách tĩnh tiếng Việt độc lập (1.942 mục đã chuẩn hóa) [3].
C3	Chỉ tầng 1 hư từ ngữ pháp, giữ cả guard phủ định.
C4	Tầng 1 cộng stoplist tầng 2 chọn theo TDV (589 từ). Bảo vệ guard ở cả tầng 1 và khi loại chiều TDV.

2.4. Mô hình không gian vector và TF-IDF

Tài liệu d và truy vấn q được biểu diễn trên tập từ vựng $\mathcal{V}$ của chỉ mục [1]. Với f(t,d) là tần suất của t trong d, df(t) là số tài liệu chứa t và N là số tài liệu, trọng số được tính như sau:

$$TF(t,d) = 1 + ln\, f(t,d) \text{ nếu } f(t,d) > 0;\ TF(t,d) = 0 \text{ nếu } f(t,d) = 0$$

$$IDF(t) = ln(\frac{N + 1}{df(t) + 1}) + 1$$

$$w(t,d) = TF(t,d) \times IDF(t)$$

TF logarithm giảm ảnh hưởng của từ lặp; IDF làm mượt với N+1, df+1, tránh chia cho 0 và bằng 1 khi df=N [4]. Với vector bất kỳ x trên $\mathcal{V}$, hệ thống dùng chuẩn L2 sau để chuẩn hóa:

$$\|x\|_2 = \sqrt{\sum_{t \in \mathcal{V}} x(t)^2}$$

2.5. Cosine similarity và phân rã đóng góp

Gọi v_q và v_d là vector TF-IDF của truy vấn q và tài liệu d. Độ tương đồng Cosine được tính như sau [5]:

$$Sim(q,d) = \frac{\sum_{t \in \mathcal{V}} w(t,q)\, w(t,d)}{\|v_q\|_2 \times \|v_d\|_2}$$

Khi hai vector đã được chuẩn hóa L2, Cosine bằng tích vô hướng. Chức năng explain liệt kê tích trọng số của từng thuật ngữ chung; tổng các đóng góp bằng điểm Cosine trong dung sai số thực. Truy vấn sử dụng từ vựng và IDF học từ corpus, không tính lại IDF theo riêng truy vấn.

2.6. Giá trị phân biệt từ TDV (Salton)

Theo Salton, thuật ngữ có khả năng phân biệt tốt giúp giảm mật độ tương đồng giữa các tài liệu [6]. Trong dự án, mật độ không gian tài liệu X là trung bình Cosine trên mọi cặp tài liệu, không gồm cặp với chính nó:

$$D(X) = \frac{1}{N(N-1)} \sum_{i=1}^{N} \sum_{\substack{j=1 \\ j \neq i}}^{N} \cos(x_i, x_j)$$

$$TDV(t) = D(X - t) - D(X)$$

Với quy ước TDV(t) = D(X − t) − D(X), TDV âm có nghĩa việc loại chiều t làm giảm mật độ Cosine trung bình. Khi thử bỏ một chiều, hệ thống chuẩn hóa L2 lại từng vector và cập nhật tổng vector dùng trong phép tính mật độ. IDF sơ bộ được giữ cố định; mỗi thuật ngữ được chấm một lần trên cùng không gian ban đầu. Dấu TDV là tiêu chí hình học, không tự chứng minh một từ không có giá trị ngữ nghĩa.

2.7. Các chỉ số đánh giá chất lượng truy xuất

Các chỉ số sau tham khảo [1]. Bộ nhãn của dự án có ba mức: 0 = không liên quan, 1 = liên quan một phần, 2 = đáp ứng trực tiếp. Với các chỉ số nhị phân, mức > 0 được coi là relevant. Ký hiệu Rq là tập tài liệu relevant đã biết của truy vấn q, Lq^K là Top-K kết quả, Q là tập truy vấn và L là độ sâu ranking. rel(r) bằng 1 nếu tài liệu ở hạng r là relevant, ngược lại bằng 0; grade(r) là nhãn 0/1/2.

$$P@K = \frac{|Rq \cap Lq^{K}|}{K} \quad Recall@K = \frac{|Rq \cap Lq^{K}|}{|Rq|}$$

$$F1@K(q) = \frac{2 \times P@K(q) \times Recall@K(q)}{P@K(q) + Recall@K(q)}$$

Công thức trên được áp dụng riêng cho từng truy vấn q; nếu mẫu số bằng 0 thì F1@K(q) được quy ước bằng 0. Khi tổng hợp trên tập truy vấn Q, các chỉ số P@K, Recall@K và F1@K được lấy trung bình macro: tính chỉ số cho từng truy vấn trước, sau đó lấy trung bình cộng với trọng số bằng nhau cho mọi truy vấn. Cụ thể:

$$Macro\text{-}F1@K = \frac{1}{|Q|}\sum_{q \in Q} F1@K(q)$$

Macro-P@K và Macro-Recall@K được tính tương tự. Do phép tính F1 là phi tuyến, Macro-F1@K nhìn chung không bằng trung bình điều hòa của Macro-P@K và Macro-Recall@K. Các truy vấn có kết quả rỗng hoặc không có tài liệu liên quan vẫn được giữ trong tập tính trung bình theo quy ước đã nêu.

$$AP(q) = \frac{1}{|Rq|}\sum_{r=1}^{L} P@r \times rel(r) \quad MAP = \frac{1}{|Q|}\sum_{q=1}^{|Q|} AP(q)$$

$$DCG@K = \sum_{r=1}^{K} \frac{2^{grade(r)} - 1}{log_2(r + 1)}$$

$$NDCG@K = \frac{DCG@K}{IDCG@K}$$

AP/MAP được tính trên toàn bộ ranking có sẵn; độ sâu yêu cầu mặc định bằng N tài liệu. Danh sách kết quả chỉ gồm các tài liệu có điểm truy xuất dương. Khi giới hạn độ sâu xếp hạng, chỉ số tương ứng được ký hiệu là AP@depth. Query không có tài liệu relevant hoặc không có kết quả được giữ điểm 0 trong trung bình macro. NDCG dùng nhãn phân cấp 0/1/2; IDCG được tính từ các nhãn đã biết của truy vấn. Bộ qrels của dự án được tạo bằng pooling hợp Top-20 của TF-IDF Cosine, binary Cosine và BM25.

2.8. Ngôn ngữ lập trình và kiến trúc giao tiếp

Python là ngôn ngữ triển khai thuật toán, đọc dữ liệu, thao tác ma trận và cung cấp HTTP API. Các lớp Preprocessor, TfidfEngine, InvertedIndex và SearchEngine chia trách nhiệm để tiền xử lý có thể được dùng lại giữa CLI, web và evaluator. Unicode và kiểu str hỗ trợ xử lý văn bản tiếng Việt; việc chuẩn hóa NFC vẫn cần thực hiện để các cách mã hóa dấu tương đương không tạo ra thuật ngữ khác nhau.

Giao diện web dùng HTML để cấu trúc biểu mẫu và bảng, CSS để bố trí, JavaScript để thu nhận đầu vào và gọi fetch bất đồng bộ. Backend dùng http.server và socketserver trong thư viện chuẩn, trả JSON qua các API GET. Trình duyệt không tự tính điểm TF-IDF trong đường chạy online: thuật toán và corpus nằm ở Python. TCPServer hiện xử lý tuần tự trong một tiến trình; phép đo độ trễ trong tiểu luận không phải kiểm thử nhiều người dùng đồng thời.

Streamlit cung cấp một giao diện Python khác cho các trang Tokenizer, Analytics và Search. Cơ chế chạy lại script theo tương tác giúp dựng nhanh trang phân tích; các xử lý cốt lõi vẫn thuộc engine. Matplotlib dùng để tạo biểu đồ từ kết quả thí nghiệm, còn pandas hỗ trợ đọc và tổng hợp bảng. Các ảnh vận hành trong tiểu luận này sử dụng giao diện HTML kết nối backend local.

2.9. Thư viện tính toán và biểu diễn ma trận thưa

NumPy cung cấp mảng số có kiểu cố định và phép tính vector hóa [7]. SciPy cung cấp csr_matrix để chỉ lưu các phần tử khác 0: data chứa giá trị, indices chứa chỉ số cột và indptr xác định đoạn dữ liệu của từng hàng [8]. Với ma trận tài liệu–thuật ngữ, mỗi hàng là một tài liệu; mỗi cột là một thuật ngữ. Cách lưu này phù hợp khi phần lớn từ vựng không xuất hiện trong một bài báo.

Chỉ mục đảo tổ chức cùng thông tin theo chiều thuật ngữ. Một term_id ánh xạ tới đoạn của mảng docs và weights thông qua offsets. Khi truy vấn có ít thuật ngữ, hệ thống duyệt posting list thay vì so với mọi chiều của mọi tài liệu. Dung lượng phụ thuộc số phần tử khác 0; chi phí truy vấn còn phụ thuộc độ dài posting của các từ được hỏi, không chỉ số lượng tài liệu. Bộ kiểm thử dùng TfidfVectorizer (sublinear_tf=True, smooth_idf=True, norm='l2') để đối soát TF-IDF [4]; các mô đun tính trọng số, lập chỉ mục và truy xuất do nhóm hiện thực bằng Python.

Bảng 2.2. Công nghệ và vai trò kỹ thuật trong dự án

Thành phần	**Phiên bản trong môi trường đo**	**Vai trò**
Python	3.13.9	Thuật toán, CLI, đọc tệp và HTTP API
NumPy / SciPy	2.4.3 / 1.17.1	Mảng số, CSR và lưu ma trận NPZ
scikit-learn	1.8.0	Đối soát trọng số và chuẩn hóa TF-IDF
Streamlit / pandas	1.66.0 / 3.0.1	Giao diện phân tích và thao tác bảng
Matplotlib	3.10.8	Biểu đồ thí nghiệm từ kết quả thật
HTML / CSS / JavaScript	Mã nguồn app/index.html	Biểu mẫu, bố cục, gọi API và hiển thị kết quả

2.10. Cơ chế lưu trữ dữ liệu cục bộ

Dự án không sử dụng một DBMS quan hệ như PostgreSQL hay MySQL. Văn bản là dạng dữ liệu đa phương tiện phi cấu trúc (Unstructured Multimedia Data). Trong các hệ quản trị CSDL truyền thống (Relational DBMS), việc truy xuất văn bản bằng các toán tử chuỗi (như LIKE) không đáp ứng được yêu cầu về hiệu năng và độ liên quan. Thay vào đó, đề tài xây dựng cấu trúc Chỉ mục đảo (Inverted Index) kết hợp mô hình vector TF-IDF và thuật toán cắt tỉa TDV Salton — đây chính là kiến trúc nền tảng được giảng dạy trong học phần nhằm phục vụ truy xuất dữ liệu đa phương tiện theo nội dung (Content-Based Information Retrieval) thay vì tra cứu khóa chính xác. Corpus được lưu JSONL để mỗi dòng là một đối tượng tài liệu; query, qrels và manifest được lưu JSON. Các mảng và ma trận được lưu NPY/NPZ. Khi server chạy, tài liệu và chỉ mục được nạp vào bộ nhớ rồi tái sử dụng qua cache. Vì không có DBMS quan hệ, hệ thống không cài đặt view, stored function hoặc trigger SQL; các kiểm tra tương ứng được thực hiện trong các hàm Python và cổng hash.

Lưu theo tệp giúp triển khai local và khóa phiên bản thí nghiệm đơn giản, nhưng không cung cấp giao dịch ACID liên tệp hay điều khiển nhiều người ghi như DBMS. Các hàm nhập kiểm

tra dữ liệu trước khi ghi từng tệp; tính toàn vẹn dựa vào ID, schema, hash và quy trình dựng lại chỉ mục.

CHƯƠNG 3. PHÂN TÍCH VÀ THIẾT KẾ HỆ THỐNG

3.1. Tác nhân và yêu cầu chức năng

Có hai nhóm thao tác: người dùng tìm kiếm và người chuẩn bị, đánh giá dữ liệu. Người dùng nhập câu hỏi, chọn cấu hình, đọc bài và xem giải thích; người chuẩn bị chạy script dựng corpus, chỉ mục, gán nhãn và đánh giá. Các vai trò được phân biệt theo thao tác sử dụng; hệ thống hiện chưa triển khai quản lý tài khoản và phân quyền truy cập.

Bảng 3.1. Yêu cầu chức năng và dữ liệu ra

Chức năng	**Đầu vào**	**Đầu ra / tiêu chí quan sát**
Tách từ	Câu tiếng Việt; FMM/BMM/BiMM	Chuỗi chuẩn hóa, token và trace
Lọc tầng 1	Câu hoặc token	Token giữ/loại và lý do guard
Tìm kiếm	Query, cấu hình, Top-K	Danh sách doc_id, score, title, snippet
Giải thích điểm	Query và doc_id	Trọng số query/document và đóng góp từng từ
Phân tích TDV	Thuật ngữ; chỉ mục C4	TDV, df và trạng thái có bị loại
Đánh giá	Corpus, query, nhãn và chỉ mục	MAP, P/R/F1/NDCG và kết quả tổng hợp

3.2. Yêu cầu phi chức năng và ranh giới hệ thống

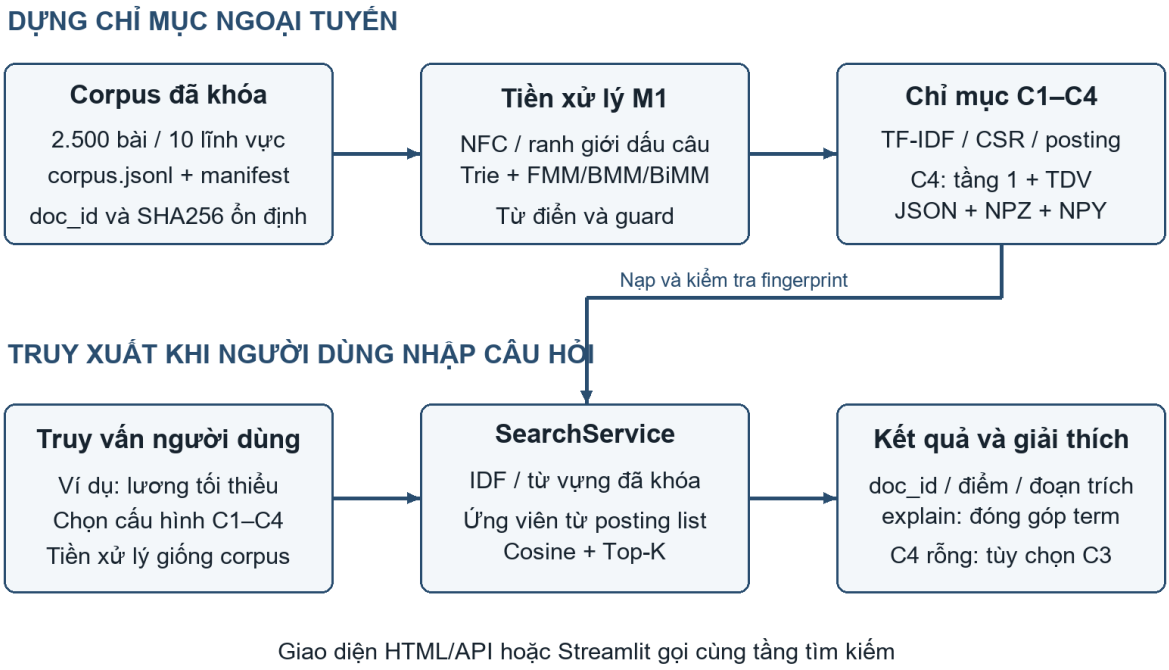
Hệ thống cần giữ đúng dấu tiếng Việt sau chuẩn hóa, dùng cùng pipeline khi dựng và truy vấn, cho thứ tự ổn định khi hòa điểm, và không tạo kết quả có điểm giả. Dữ liệu và chỉ mục phải nhất quán về phiên bản. Mục tiêu thực nghiệm là mean truy vấn dưới 30 ms trong điều kiện chỉ mục nạp sẵn và giảm ít nhất 30% byte phục vụ của cấu hình thử nghiệm so với C1. Đây là mục tiêu đo trên tập và máy đã định, không phải cam kết cho mọi quy mô hoặc mọi máy.

3.3. Thiết kế kiến trúc tổng thể

Kiến trúc gồm tầng xử lý ngôn ngữ M1 (engine.tokenizer), tầng truy xuất M2 (engine.indexer), giao diện HTML/API và Streamlit, cùng các công cụ đánh giá và benchmark. M1 phụ trách chuẩn hóa, Trie, FMM/BMM/BiMM và lọc tầng 1; M2 phụ trách TF-IDF, chỉ mục đảo, TDV và xếp hạng Cosine. Cách tổ chức này tách trách nhiệm xử lý ngôn ngữ khỏi lập chỉ mục và xếp hạng.

Luồng truy vấn gồm chuẩn hóa văn bản, tách từ BiMM, lọc từ dừng theo cấu hình, vector hóa bằng từ vựng và IDF của corpus, hợp posting list để lấy ứng viên, tính điểm Cosine và trả Top-K. Mỗi kết quả có doc_id, tiêu đề, điểm và đoạn trích. Khi hòa điểm, hệ thống sắp doc_id tăng dần. Từ ngoài từ vựng không tạo chiều mới trong vector truy vấn.

Hình 3.1 phân biệt đường dựng chỉ mục ngoại tuyến với đường trả lời truy vấn khi vận hành. Hai đường dùng chung tài nguyên và quy tắc tiền xử lý.



Hình 3.1. Kiến trúc dựng chỉ mục và truy xuất văn bản

Đường ngoại tuyến tính từ vựng, df, IDF và trọng số một lần theo corpus; C4 còn tính TDV. Đường trực tuyến chỉ biến đổi query bằng không gian đã khóa và lấy ứng viên. Việc tách hai đường tránh tính lại IDF theo từng câu hỏi, đồng thời cho phép đối soát bốn chính sách từ dừng trên cùng dữ liệu.

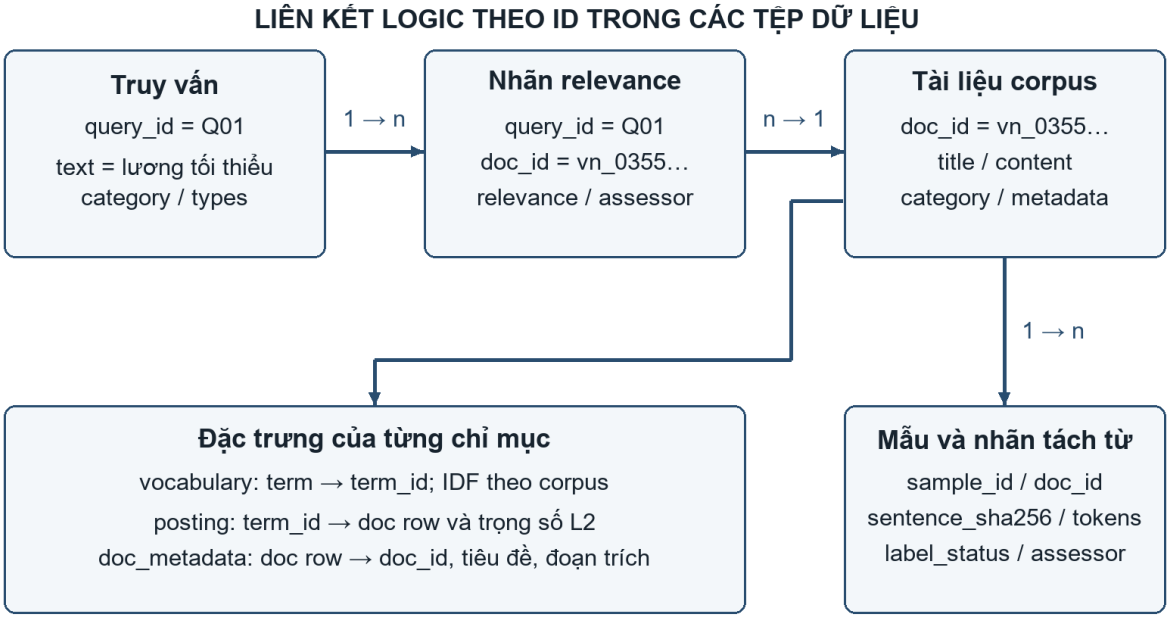
3.4. Thiết kế đối tượng và liên kết dữ liệu

Bảng 3.2 mô tả các đối tượng dữ liệu, khóa liên kết và cơ chế kiểm tra tính toàn vẹn của hệ thống.

Bảng 3.2. Đối tượng dữ liệu và khóa liên kết logic

Đối tượng	**Khóa / trường chính**	**Ý nghĩa và kiểm tra**
Tài liệu	doc_id; title; content; category; metadata	ID ổn định, nội dung khớp corpus khóa
Truy vấn	query_id; text; category; types	20 câu khóa; category không tự quyết định relevance
Judgment	query_id + doc_id; relevance; status; assessor	Cặp duy nhất; relevance 0/1/2; chỉ dùng confirmed
Gold tách từ	sample_id; doc_id; sentence_sha256; tokens	Token giữ đủ âm tiết, không vượt dấu câu
Từ vựng / posting	term_id; offsets; docs; weights	Chỉ số cột và hàng hợp lệ; trọng số L2
Manifest	SHA256; schema; preprocessing fingerprint	Từ chối đầu vào hoặc chỉ mục không cùng phiên bản

Hình 3.2 biểu diễn liên kết theo ID giữa các tệp JSON/JSONL và các đặc trưng của chỉ mục.



Hình 3.2. Liên kết logic giữa tài liệu truy vấn nhãn và đặc trưng

3.5. Thiết kế luồng tìm kiếm và xử lý ngoại lệ

Một query đi qua các bước: chuẩn hóa có ranh giới; tách từ; lọc theo cấu hình; lấy các term có trong vocabulary; gán TF-IDF bằng IDF của corpus; chuẩn hóa L2; hợp posting list; tính Cosine; sắp điểm giảm dần và doc_id tăng dần khi hòa. Query rỗng, toàn OOV hoặc có vector 0 trả danh sách rỗng. Với C4 bật dự phòng, SearchService có thể chuyển sang chỉ mục C3 riêng khi không có kết quả, đồng thời ghi requested_configuration, used_configuration và fallback_used.

Thiết kế giải thích điểm sử dụng chính các trọng số L2 đã dùng khi xếp hạng. Tổng tích trọng số của các thuật ngữ chung bằng điểm Cosine trong dung sai số thực. Khi fallback xảy ra, phần giải thích sử dụng chỉ mục C3 đã trả kết quả, bảo đảm nhất quán với các trọng số dùng để xếp hạng.

Các thuật toán cốt lõi được cụ thể hóa trong Chương 4. Thuật toán 4.1 trình bày quá trình tách từ BiMM và lựa chọn kết quả giữa hai chiều quét. Thuật toán 4.2 mô tả cách tích lũy điểm Cosine qua chỉ mục đảo để trả về Top-K tài liệu. Thuật toán 4.3 trình bày cách tính TDV one-shot trên ma trận thưa, có chuẩn hóa lại vector và cập nhật tổng vector khi thử loại từng chiều thuật ngữ.

3.6. Thiết kế bố cục và tương tác giao diện

Giao diện HTML gồm thanh điều hướng bên trái và vùng nội dung bên phải. Vùng Search có query, cấu hình, lựa chọn fallback và danh sách kết quả; mỗi kết quả có nút đọc bài và mở bảng trọng số. Vùng Tokenizer có ba thẻ cho tách từ, lọc tầng 1 và tài nguyên. Vùng Analytics phục vụ tra thuật ngữ TDV. Các trường được nhóm theo trình tự nhập dữ liệu, chạy xử lý và đọc kết quả; ảnh vận hành được trình bày tại Hình 5.1 đến Hình 5.5.

CHƯƠNG 4. HIỆN THỰC HỆ THỐNG

4.1. Tổ chức mã nguồn và các mô đun

Bảng 4.1 nối các khối của thiết kế với các tệp và lớp hiện có trong mã nguồn dự án.

Bảng 4.1. Mô đun hiện thực và trách nhiệm

Thành phần	**Đường dẫn / lớp**	**Trách nhiệm**
Chuẩn hóa và tách từ	engine/tokenizer; MaximumMatching	NFC, đoạn dấu câu, Trie, FMM/BMM/BiMM
Tiền xử lý tích hợp	engine/preprocessing.py; Preprocessor	Chọn pipeline và fingerprint tài nguyên
TF-IDF và posting	TfidfEngine; InvertedIndex	Vocabulary, IDF, CSR và posting list
Tìm kiếm / dự phòng	SearchEngine; scripts/search.py	Top-K, explain, lưu/nạp; fallback C3
Lọc theo TDV	engine/indexer/tdv_engine.py	Mật độ Cosine và stoplist miền
Web và phân tích	app/server.py; app/index.html; app/pages	HTTP API, HTML và Streamlit
Chuẩn bị / đánh giá	scripts; evaluator; benchmarks	Chuẩn bị dữ liệu, gán nhãn, đánh giá và tổng hợp kết quả

4.2. Hiện thực xử lý ngôn ngữ

Tiền xử lý chuẩn hóa Unicode NFC, chuyển chữ thường, loại HTML, URL, email, số và các ký tự không dùng làm thuật ngữ. Các chữ Latin f, j, w, z được giữ để hỗ trợ tên riêng và từ mượn; chuỗi không có trong từ điển được xử lý là token ngoài từ điển. Hàm normalize tạo chuỗi hiển thị, còn normalize_segments giữ các đoạn để bộ tách từ không nối từ qua ranh giới dấu câu hoặc nội dung đã bị loại.

Từ điển được làm sạch từ nguồn Viet74K [9] (ghim snapshot + giấy phép GPL-2.0): còn 69.858 mục sau chuẩn hóa; scripts.clean_dict xác thực nguồn và cho phép sinh lại kết quả giống hệt theo byte. Khi dựng chỉ mục, từ vựng của corpus C1 gồm 31.194 thuật ngữ. Cấu trúc Trie cho phép dò tiền tố theo âm tiết; cửa sổ trượt tối đa bằng độ dài mục dài nhất của từ điển (17 âm tiết). FMM/BMM đều phát ra vết (trace) theo từng bước: hướng, chỉ số âm tiết, ứng viên, kích thước, kết quả MATCHED/SHRINK/SINGLE; BiMM đánh dấu các dòng của chiều thắng. Vết dùng cho trang Tokenizer của giao diện để minh bạch thuật toán.

MaximumMatching nhận từ điển, xác định cửa sổ theo mục dài nhất và gọi chuẩn hóa có phân đoạn trước khi quét. Trace ghi candidate, start, end, size, matched, action và hướng fmm/bmm. Khi hiển thị web, hai giá trị hướng này được ánh xạ sang FORWARD/BACKWARD. API tokenize nhận text và method; cửa sổ của backend được xác định theo cấu hình từ điển và được giữ thống nhất trong thí nghiệm, chưa có khảo sát riêng về ảnh hưởng của tham số này.

Thuật toán 4.1 mô tả bộ tách từ BiMM sử dụng từ điển Trie. Văn bản được chuẩn hóa và chia thành các đoạn có ranh giới trước khi thực hiện so khớp. FMM quét từng đoạn từ trái sang phải, còn BMM quét từ phải sang trái. Tại mỗi vị trí, thuật toán thử các chuỗi âm tiết từ dài đến ngắn

trong giới hạn cửa sổ và chọn chuỗi đầu tiên có trong Trie. Nếu không tìm thấy chuỗi phù hợp, thuật toán nhận một âm tiết làm token. Các token của BMM được đưa về thứ tự trái sang phải trước khi so sánh.

Thuật toán 4.1. Tách từ BiMM sử dụng Trie

Đầu vào: văn bản s; từ điển Trie T; cửa sổ tối đa L.
Đầu ra: danh sách token được chọn.

segments ← Chuẩn_hóa_và_chia_đoạn(s)

F ← danh sách rỗng; B ← danh sách rỗng

Với mỗi đoạn g trong segments:

F ← F nối FMM(g, T, L)

B ← B nối BMM(g, T, L), đã đưa về thứ tự trái sang phải

nF ← số token của F; nB ← số token của B

sF ← số token đơn âm tiết của F

sB ← số token đơn âm tiết của B

oF ← số token của F không có trong T

oB ← số token của B không có trong T

keyF ← (nF, sF, oF); keyB ← (nB, sB, oB)

Nếu keyB ≤ keyF theo thứ tự từ điển:

Trả về B

Ngược lại:

Trả về F

Hai bộ khóa được so sánh lần lượt từ trái sang phải: số token, số token đơn âm tiết và số token ngoài từ điển. Tiêu chí sau chỉ được xét khi các tiêu chí trước bằng nhau. Nếu hai bộ khóa bằng nhau hoàn toàn, thuật toán chọn BMM. Như vậy, BiMM sử dụng ba tiêu chí so sánh và một quy tắc phá hòa. Việc lựa chọn được thực hiện trên kết quả đầy đủ của mỗi chiều; các bước so khớp không vượt qua ranh giới đoạn. Token nhiều âm tiết được biểu diễn bằng dấu gạch dưới để phục vụ các bước lập chỉ mục tiếp theo.

4.3. Hiện thực TF-IDF chỉ mục đảo và giải thích

Ma trận trọng số được lưu dưới dạng CSR thưa, kèm từ vựng, IDF và posting list. Truy vấn dùng đúng tokenizer, bộ lọc, từ vựng và IDF của chỉ mục. Từ ngoài từ vựng không tạo chiều mới; query rỗng hoặc vector 0 trả danh sách rỗng. Bộ nạp kiểm tra fingerprint của nguồn và tài nguyên, từ chối chỉ mục không còn khớp tiền xử lý. Cả bốn cấu hình được dựng với cùng phiên bản nguồn tiền xử lý.

InvertedIndex lưu offsets bằng int64, docs bằng int32 và weights bằng float64. Với term_id = t, đoạn offsets[t]:offsets[t+1] xác định posting list. Truy vấn cộng query_weight ×

document_weight vào các ứng viên tương ứng. SearchEngine giữ doc_id, tiêu đề, lĩnh vực và đoạn trích để trả kết quả mà không đọc lại raw. Các phép cộng dùng số thực nên kiểm chứng explain dùng dung sai thay vì yêu cầu bằng nhau tuyệt đối theo chuỗi thập phân.

Thuật toán 4.2 dùng chung tiền xử lý, từ vựng và IDF với chỉ mục đã dựng. Trong mã giả, vq là biến lưu vector truy vấn v_q; wd[t] là trọng số của t trong vector tài liệu đã chuẩn hóa L2. Sau chuẩn hóa L2 cho truy vấn, điểm Cosine bằng tổng tích trọng số trên các thuật ngữ chung.

Thuật toán 4.2. Tính điểm Cosine qua posting list và trả về Top-K

Đầu vào: truy vấn q; chỉ mục I; số kết quả K.
Đầu ra: tối đa K tài liệu có điểm Cosine dương.

```
Kiểm tra K là số nguyên không âm; báo lỗi nếu không hợp lệ
Nếu K = 0: trả về danh sách rỗng
tokens ← Tiền_xử_lý(q, cấu hình của I)
vq ← TF_IDF_truy_vấn(tokens, vocabulary và IDF của I)
vq ← Chuẩn_hóa_L2(vq)
Nếu vq không có phần tử khác 0: trả về danh sách rỗng
C ← Hợp các posting list của những thuật ngữ trong vq
Nếu C rỗng: trả về danh sách rỗng
Khởi tạo score[d] ← 0 với mọi tài liệu d trong C
Với mỗi thuật ngữ t có trọng số vq[t] khác 0:
    Với mỗi cặp (d, wd[t]) trong posting list của t:
        score[d] ← score[d] + vq[t] × wd[t]
R ← Các tài liệu trong C có score[d] > 0
Sắp R theo score giảm dần; nếu hòa thì doc_id tăng dần
Trả về tối đa K tài liệu đầu của R cùng điểm và thông tin
```

Tập ứng viên chỉ gồm các tài liệu xuất hiện trong ít nhất một posting list của truy vấn. Thuật ngữ ngoài từ vựng không tạo thêm chiều mới. Nếu truy vấn không còn thuật ngữ sử dụng được hoặc không có tài liệu đạt điểm dương, kết quả trả về là danh sách rỗng. Bản hiện thực sắp thứ tự các ứng viên rồi lấy tối đa K phần tử đầu. Chức năng giải thích điểm sử dụng cùng các tích trọng số đã tham gia tính Cosine, bảo đảm tổng đóng góp của các thuật ngữ khớp điểm xếp hạng trong dung sai số thực.

4.4. Hiện thực TDV và cơ chế dự phòng

TDV được tính trên 31.076 thuật ngữ sau lọc tầng 1: 666 thuật ngữ có TDV âm dưới dung sai, 77 thuật ngữ được chính sách guard bảo vệ, còn 589 thuật ngữ bị loại ở tầng 2. Từ vựng C4 còn 30.487 thuật ngữ so với 31.194 ở C1. Có đường tính nhanh trên ma trận thưa và đường tham chiếu dựng lại Cosine trực tiếp để đối soát trên tập nhỏ. Khi C4 không còn thuật ngữ truy vấn

sử dụng được, hệ thống có thể truy xuất bằng chỉ mục C3 riêng. Kết quả và dung lượng của C4 thuần và gói fallback được báo cáo riêng.

TDV được tính sau tầng 1 với IDF sơ bộ cố định. Mỗi lần thử bỏ một chiều, các vector được chuẩn hóa lại và tổng vector được cập nhật. Quy trình hiện tại là one-shot, không phải loại liên tiếp rồi chấm lại TDV. Sau khi chọn các điểm âm dưới dung sai 10^{-12}, guard loại các chiều cần bảo vệ khỏi stoplist. SearchService chỉ nạp C3 bổ sung khi cần fallback; dung lượng lưu trữ của gói triển khai có fallback gồm cả chỉ mục C3 và C4.

Thuật toán 4.3 tính TDV trên ma trận TF-IDF sơ bộ sau lọc tầng 1. Ma trận X được chuẩn hóa L2 theo hàng; mỗi hàng x_i biểu diễn một tài liệu. Đặt $r_i = \|x_i\|_2^2$ và $S = \Sigma_i x_i$. Mật độ ban đầu được tính bằng:

$$D_0 = (\|S\|_2^2 - \Sigma_i r_i) / [N(N - 1)].$$

Đẳng thức này loại đóng góp của các cặp tài liệu với chính chúng mà không cần dựng ma trận Cosine N × N. Khi thử bỏ thuật ngữ t, chỉ các hàng chứa t cần thay đổi hệ số chuẩn hóa. Cấu trúc CSC xác định các hàng này; cấu trúc CSR hỗ trợ đọc các phần tử khác 0 của từng hàng để cập nhật tổng vector.

Thuật toán 4.3. Tính TDV one-shot trên ma trận thưa

Đầu vào: ma trận TF-IDF sơ bộ X; tập thuật ngữ bảo vệ G; dung sai $\varepsilon = 10^{-12}$.
Đầu ra: điểm TDV của từng thuật ngữ và stoplist tầng 2.

N ← số hàng của X; M ← số cột của X (= $|\mathcal{V}|$)

Nếu N < 2: trả về các điểm TDV bằng 0 và stoplist rỗng

r[i] ← ||x[i]||₂²; S ← Σ_i x[i]

D0 ← (||S||₂² − Σ_i r[i]) / (N × (N − 1))

Với mỗi thuật ngữ t từ 1 đến M:

A ← Các hàng có X[i,t] khác 0, lấy từ cấu trúc CSC

Nếu A rỗng: TDV[t] ← 0; chuyển sang thuật ngữ tiếp theo

Với mỗi i trong A: v[i] ← X[i,t]

a[i] ← 1 / sqrt(r[i] − v[i]²) nếu hiệu dương; ngược lại 0

S_t ← S + Σ_{i∈A} (a[i] − 1) × x[i], tích lũy bằng CSR

B_t ← Σ_i r[i] + Σ_{i∈A} (a[i]² − 1) × r[i]

p_t ← Σ_{i∈A} a[i] × v[i]; h_t ← Σ_{i∈A} (a[i] × v[i])²

D_t ← (||S_t||₂² − B_t − p_t² + h_t) / (N × (N − 1))

TDV[t] ← D_t − D0

Trả về TDV và {t | TDV[t] < −ε và t không thuộc G}

Trong tính toán số thực, hiệu $r_i - v_i^2$ được chặn dưới tại 0 trước khi lấy căn. Hệ số a_i bằng 0 khi tài liệu trở thành vector 0 sau khi bỏ chiều t. Đại lượng S_t ở dòng 10 là tổng vector sau khi điều

chỉnh hệ số chuẩn hóa nhưng vẫn giữ thành phần t; hai số hạng $-p_t^2 + h_t$ ở dòng 13 hiệu chỉnh việc loại thành phần này và loại đóng góp trên đường chéo.

Mỗi thuật ngữ được đánh giá trên cùng ma trận X ban đầu, với IDF sơ bộ giữ cố định. Vì vậy, đây là phép tính one-shot, không phải quy trình loại từ liên tiếp rồi tính lại TDV. Các thuật ngữ có TDV nhỏ hơn $-\varepsilon$ được đề xuất loại bỏ; chính sách guard tiếp tục giữ lại các thuật ngữ cần bảo vệ. Sau khi xác định stoplist tầng 2, hệ thống dựng lại chỉ mục TF-IDF phục vụ C4. Đường tính trực tiếp trên tập nhỏ được dùng để đối soát kết quả của đường tính nhanh.

4.5. Hiện thực lưu trữ và kiểm tra phiên bản

Bảng 4.2 mô tả tệp vật lý tương ứng với các đối tượng ở Bảng 3.2 và Hình 3.2.

Bảng 4.2. Tệp lưu trữ và đường truy cập dữ liệu

Tệp / nhóm tệp	**Định dạng**	**Nội dung và cách sử dụng**
corpus.jsonl / corpus_manifest.json	JSONL / JSON	Văn bản và hash corpus khóa
queries.json / qrels.json	JSON	Nội dung query và nhãn theo cặp ID
segmentation_sample / labels	JSONL	Câu nguồn, hash và token người xác nhận
vocabulary / idf_weights	JSON	term → term_id và IDF corpus
tf_counts.npz / doc_norms.npy	NPZ / NPY	Tần suất thưa và norm theo tài liệu
inverted_index.npz	NPZ	offsets, docs và trọng số dùng truy vấn
build_metadata / manifest	JSON	Schema, hash artifact và fingerprint nguồn

Để bảo đảm tính toàn vẹn dữ liệu và tính tái lập giữa các tệp lưu trữ trên, hệ thống áp dụng bốn quy tắc kiểm soát xuyên suốt:

- Bảo vệ phủ định: giữ dấu hiệu phủ định ở tầng 1 và khi chọn chiều TDV. Điều này hạn chế mất thông tin từ vựng; mô hình túi từ vẫn không suy luận được đầy đủ ngữ nghĩa phủ định.
- Xử lý hòa điểm: khi điểm bằng nhau, sắp doc_id tăng dần để kết quả tái lập được.
- Tính nhất quán dữ liệu: kiểm tra phiên bản corpus, truy vấn, nhãn và cấu hình tiền xử lý trước khi đánh giá; bảo đảm các cấu hình được so sánh trên cùng bộ dữ liệu.
- Kiểm tra nhãn: xác định mức liên quan theo nội dung tài liệu; kiểm tra token tham chiếu bảo toàn thứ tự âm tiết và ranh giới dấu câu.

4.6. API và hiện thực giao diện

Bảng 4.3 tổng hợp các API GET giữa giao diện JavaScript và backend Python, gồm tham số đầu vào và dữ liệu phản hồi.

Bảng 4.3. Các API GET phục vụ giao diện

API	**Tham số chính**	**Dữ liệu trả về**
/api/status	Không có	Số tài liệu, các chỉ mục sẵn có
/api/search	q; config; top_k; fallback	Kết quả, requested/used configuration và thời gian
/api/explain	q; doc_id; config; used_config	score và contributions theo term

/api/tokenize	text; method	Văn bản chuẩn hóa, token, trace
/api/tier1	text	Token trước/sau và báo cáo giữ/loại
/api/corpus_doc	doc_id	Toàn văn và metadata của bài
/api/tdv	term; limit	TDV, df và trạng thái bị loại
/api/resources	Không có	Tài nguyên và số mục đọc được

SearchAPIHandler phân tích đường dẫn và tham số truy vấn, gọi SearchService rồi trả JSON UTF-8. Frontend cập nhật giao diện sau khi nhận phản hồi. Khi không có kết quả, giao diện hiển thị thông báo tương ứng; khi kết nối lỗi, giao diện thông báo lỗi. Cấu hình thực sự được sử dụng và trạng thái fallback được hiển thị cùng kết quả; chức năng giải thích lấy trọng số từ đúng chỉ mục đã thực hiện truy xuất.

Trang tổng quan hiện sử dụng một số chỉ tiêu tổng hợp tĩnh. Các kết quả thực nghiệm trong tiểu luận được tính từ bộ đánh giá thống nhất ở Chương 5; các ảnh vận hành minh họa phản hồi thực tế của hệ thống khi xử lý truy vấn.

CHƯƠNG 5. VẬN HÀNH HỆ THỐNG VÀ ĐÁNH GIÁ

5.1. Môi trường và chuẩn bị dữ liệu

Các chỉ mục được dựng lại từ corpus khóa bằng BiMM và tài nguyên trong mã nguồn dự án. Mỗi truy vấn được lặp 100 lần, có 5 lượt warm-up, Top-10 và chỉ mục đã nạp sẵn. Phép đo không gồm thời gian khởi động Python, nạp từ điển, đọc chỉ mục ban đầu hoặc vẽ giao diện. Bộ benchmark gồm 20 truy vấn, tương ứng 2.000 lượt đo cho mỗi cấu hình.

Corpus của đề tài được xây dựng từ VNTC (Vietnamese News Text Classification Corpus), phiên bản 10Topics/Ver1.1, phần Train_Full được phân phối tại kho GitHub duyvuleo/VNTC [10]. Tệp Stats.txt của nguồn ghi 33.759 bài thuộc 10 chủ đề, lấy từ VnExpress, Tuổi Trẻ, Thanh Niên và Người Lao Động. Bản cục bộ được ghi nhận trong manifest gồm 33.759 tệp TXT UTF-16 LE BOM. Sau chuẩn hóa, loại bài dưới 100 đơn vị phân tách bằng khoảng trắng và khử trùng MD5 trên toàn tập, lấy mẫu với seed 2026 để chọn 250 bài/lĩnh vực. Corpus chính có 2.500 bài và được khóa bằng SHA256; độ dài văn bản ở bước lọc được đo theo các đơn vị phân tách bằng khoảng trắng trước khi thực hiện tách từ tiếng Việt.

Bảng 5.1 trình bày quy mô nguồn và corpus; số liệu nguồn được đọc từ manifest đã lưu.

Bảng 5.1. Thống kê dữ liệu và corpus được chọn

Hạng mục	**Giá trị**
Tệp raw đọc được	33.759 (UTF-16 LE BOM, đủ 10 thư mục)
Bản hợp lệ sau chuẩn hóa	32.748
Bản bị loại dưới 100 đơn vị	1.011
Bản trùng loại (MD5)	49 (49 trùng chéo lĩnh vực)
Corpus chọn	2.500 bài; 10 lĩnh vực; 250 bài/lĩnh vực; seed 2026
Khối lượng corpus	8,52 MB JSONL UTF-8

Bộ đánh giá gồm 20 truy vấn, hai truy vấn mỗi lĩnh vực, bao gồm câu ngắn, câu dài, thuật ngữ chuyên ngành và phủ định (Phụ lục C). Tập ứng viên gán nhãn được tạo bằng hợp Top-20 của TF-IDF Cosine, binary presence Cosine và BM25 (k1 = 1,2; b = 0,75), thu được 669 cặp truy vấn–tài liệu. Mỗi cặp được gán một trong ba mức: 0 – không liên quan, 1 – liên quan một phần, 2 – đáp ứng trực tiếp nhu cầu truy vấn. Một số trường hợp tiêu biểu được trình bày tại Phụ lục A.

Khi tính các chỉ số truy xuất, tài liệu chưa có nhãn trong qrels được xử lý như không liên quan. Quy ước này không tương đương với một phán quyết không liên quan đã được người chấm xác nhận. Vì pool chỉ gồm một phần corpus, các chỉ số chất lượng được diễn giải trong phạm vi bộ nhãn hiện hành.

Tập nhãn đã được rà soát có mục tiêu ở một số trường hợp cần làm rõ; chưa có vòng chấm độc lập toàn bộ bộ dữ liệu và chưa xác định độ đồng thuận giữa các người chấm. Do đó, kết quả chất lượng phản ánh hiệu năng trên bộ nhãn hiện hành, chưa đủ để suy rộng cho mọi truy vấn hoặc mọi kho văn bản.

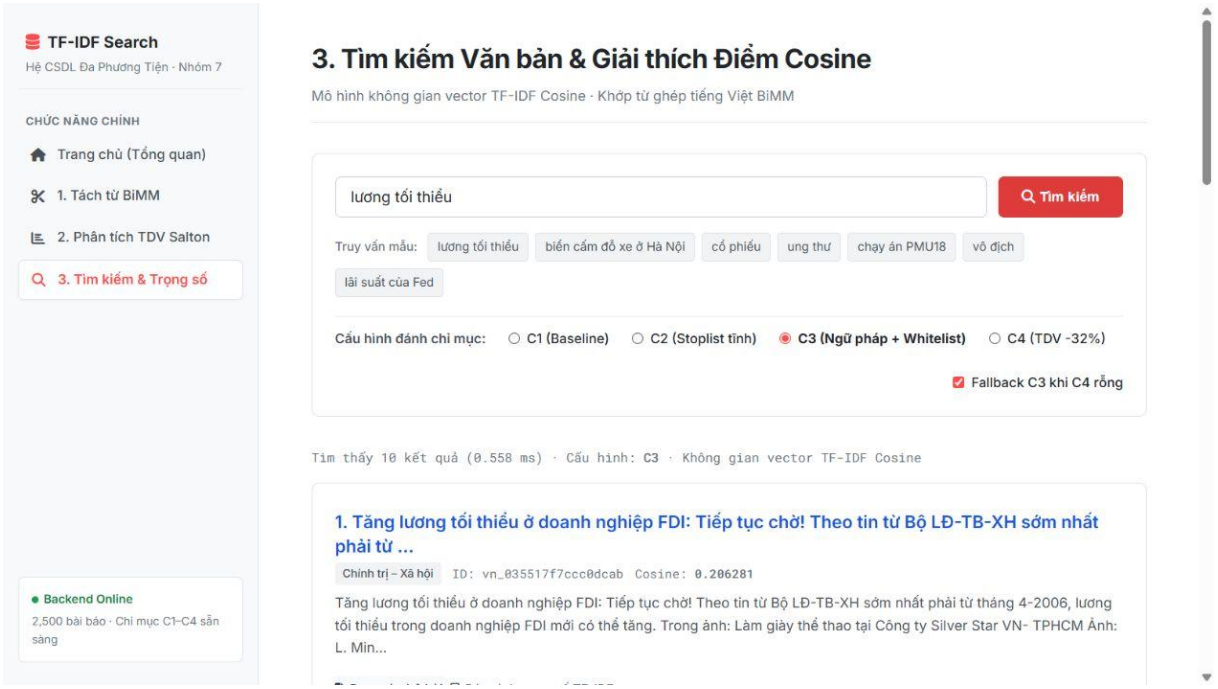
Sau khi cài requirements-dev.txt trong môi trường Python, chạy python -X utf8 -m scripts.build_indexes để dựng C1–C4. Chạy python -X utf8 app/server.py --port 8000 --no-browser rồi mở http://localhost:8000. Có thể chạy python -X utf8 -m streamlit run app/Home.py để dùng giao diện phân tích. Phiên chụp minh họa dùng cổng 8766 để tránh xung đột cổng; cổng này không làm thay đổi dữ liệu hoặc thuật toán.

Hình 5.1 đến Hình 5.5 minh họa các chức năng vận hành với đầu vào và kết quả thực tế. Thời gian hiển thị ở từng ảnh là thời gian của một thao tác; độ trễ trung bình được đo riêng bằng phép thử lặp tại Bảng 5.5.

5.2. Tìm kiếm văn bản với dữ liệu thực

Nhập "lương tối thiểu", chọn C3 và bấm Tìm kiếm. Hệ thống trả Top-10; bài đứng đầu có doc_id vn_035517f7ccc0dcab, điểm Cosine xấp xỉ 0,206281. Thẻ kết quả cho biết lĩnh vực, mã bài, đoạn trích, nút đọc toàn văn và nút xem trọng số. Thông tin lĩnh vực hỗ trợ diễn giải kết quả; nhãn relevance được xác định từ nội dung tài liệu và mức độ đáp ứng truy vấn.

Hình 5.1 ghi lại màn hình sau khi backend trả kết quả thật, gồm câu truy vấn, C3 đang được chọn và tài liệu đứng đầu.

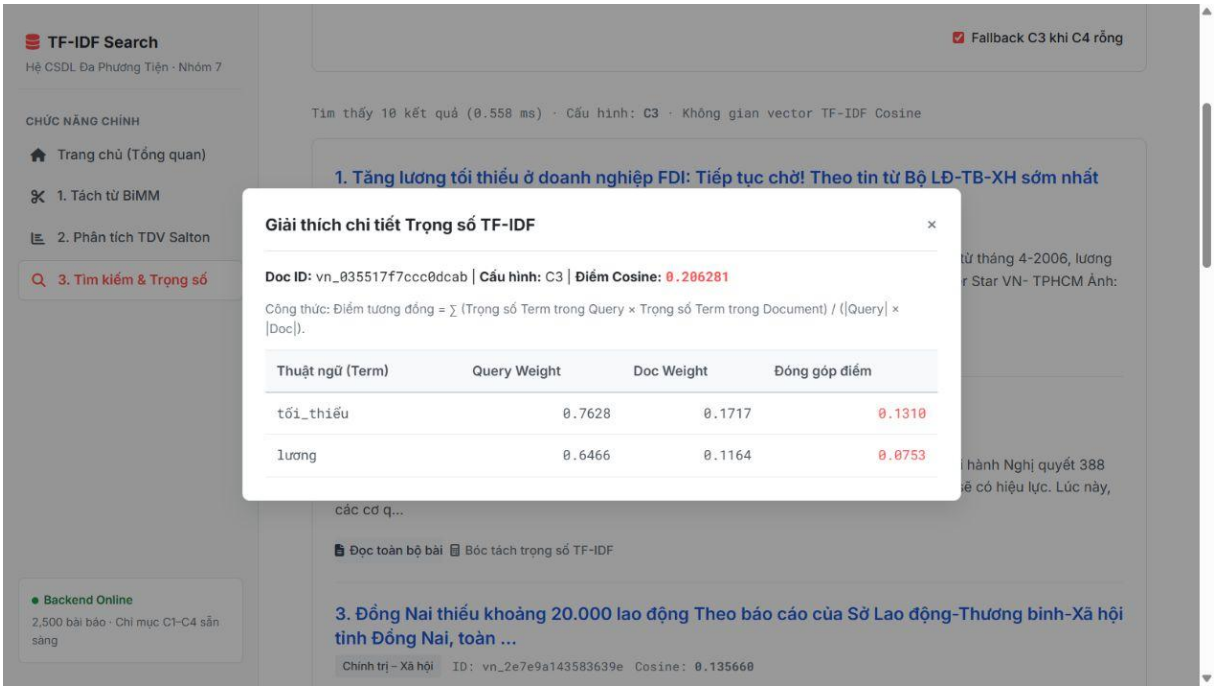


Hình 5.1. Tìm kiếm lương tối thiểu bằng cấu hình C3

5.3. Giải thích điểm Cosine của một kết quả

Từ bài đứng đầu ở Hình 5.1, chọn Bóc tách trọng số TF-IDF. Hai term chung là tối_thiểu và lương. Đóng góp chưa làm tròn lần lượt khoảng 0,1310140593 và 0,0752665208, tổng bằng 0,2062805801. Các trọng số được trả từ engine đã chuẩn hóa L2, nên điểm Cosine được xác định trực tiếp bằng tổng các tích trọng số.

Hình 5.2 cho thấy doc_id, cấu hình C3, điểm Cosine và bảng đóng góp theo thuật ngữ của cùng kết quả ở Hình 5.1.

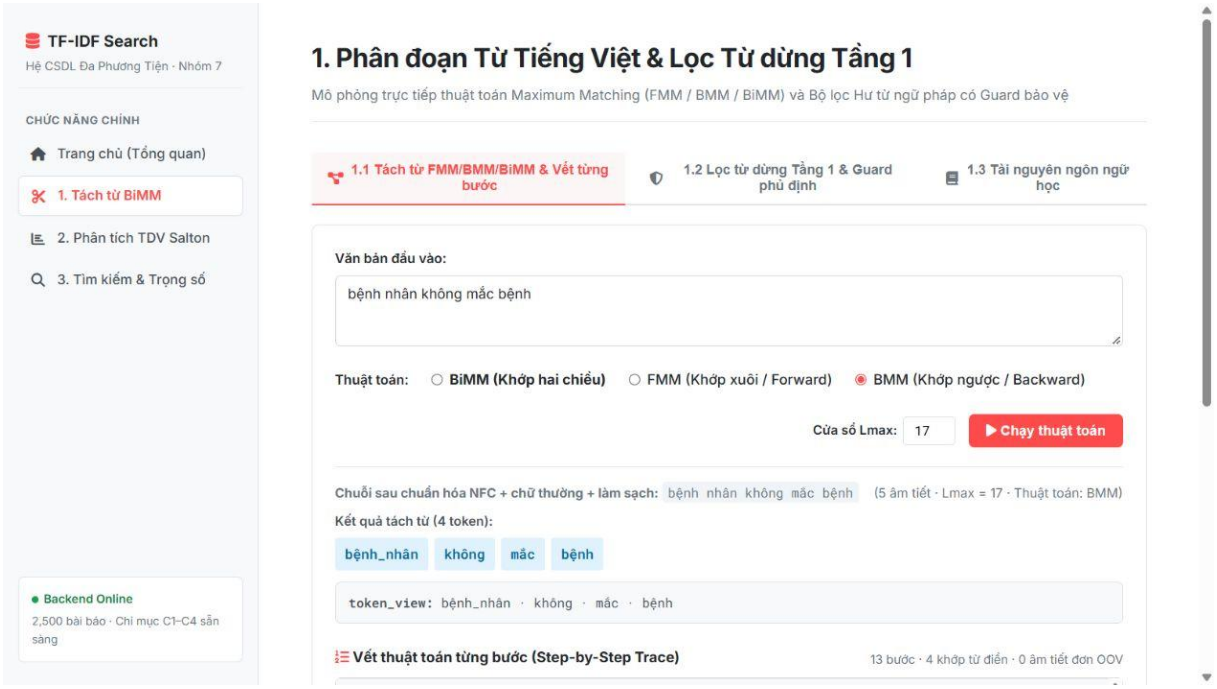


Hình 5.2. Giải thích trọng số của kết quả đứng đầu truy vấn lương tối thiểu

5.4. Vận hành chức năng tách từ

Mở Tokenizer, nhập "bệnh nhân không mắc bệnh", chọn BMM và bấm Chạy thuật toán. Đầu ra gồm bệnh_nhân, không, mắc, bệnh; trace có 13 bước và bốn lần khớp từ điển cho câu này. Ảnh minh họa đặt Lmax hiển thị là 17 để khớp cấu hình từ điển của backend. Ví dụ này minh họa thao tác tách từ; chất lượng tổng thể được đánh giá trên 150 câu tại Bảng 5.3.

Hình 5.3 thể hiện câu đầu vào, phương pháp BMM được chọn, chuỗi chuẩn hóa và bốn token trả về từ backend.

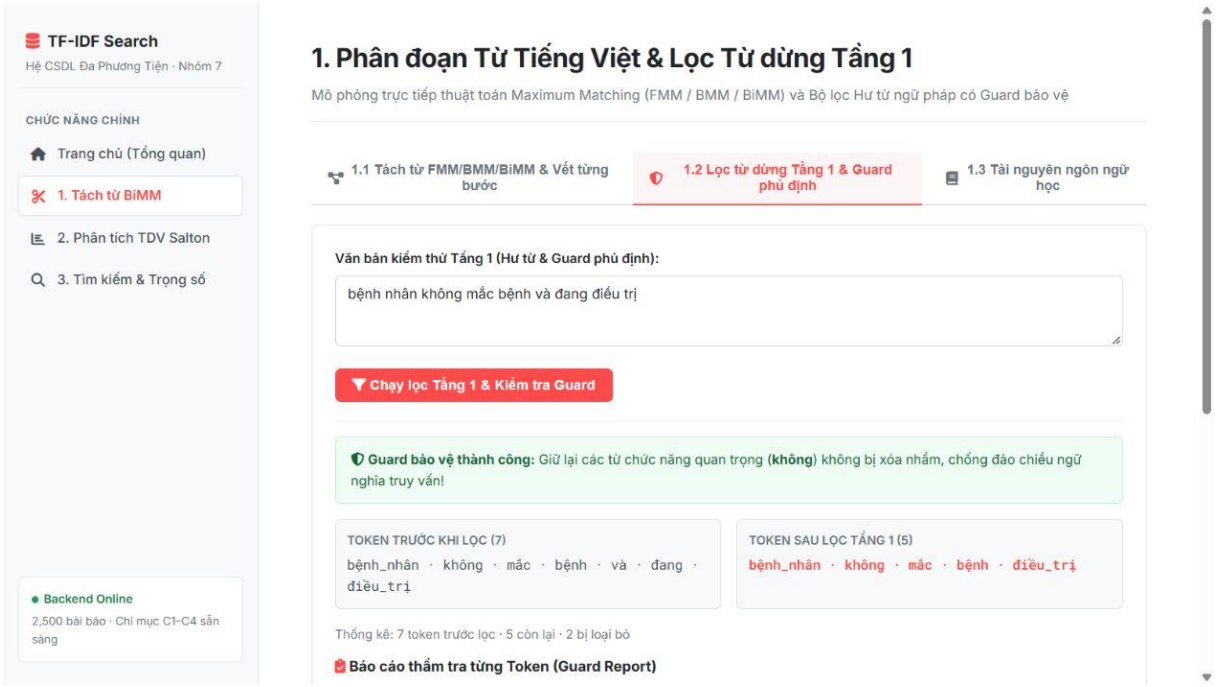


Hình 5.3. Tách từ BMM cho câu bệnh nhân không mắc bệnh

5.5. Vận hành lọc từ dừng và guard

Nhập “bệnh nhân không mắc bệnh và đang điều trị” ở thẻ Lọc từ dừng Tầng 1. Tokenizer tạo bảy token; bộ lọc loại và, đang, còn lại bệnh_nhân, không, mắc, bệnh, điều_trị. Từ không được giữ nhờ guard. Cơ chế guard bảo vệ dấu hiệu phủ định ở mức từ vựng; khả năng biểu diễn ngữ nghĩa của câu vẫn chịu giới hạn của mô hình túi từ.

Hình 5.4 minh họa dữ liệu trước và sau lọc, với hai token bị loại và dấu hiệu phủ định được giữ lại.

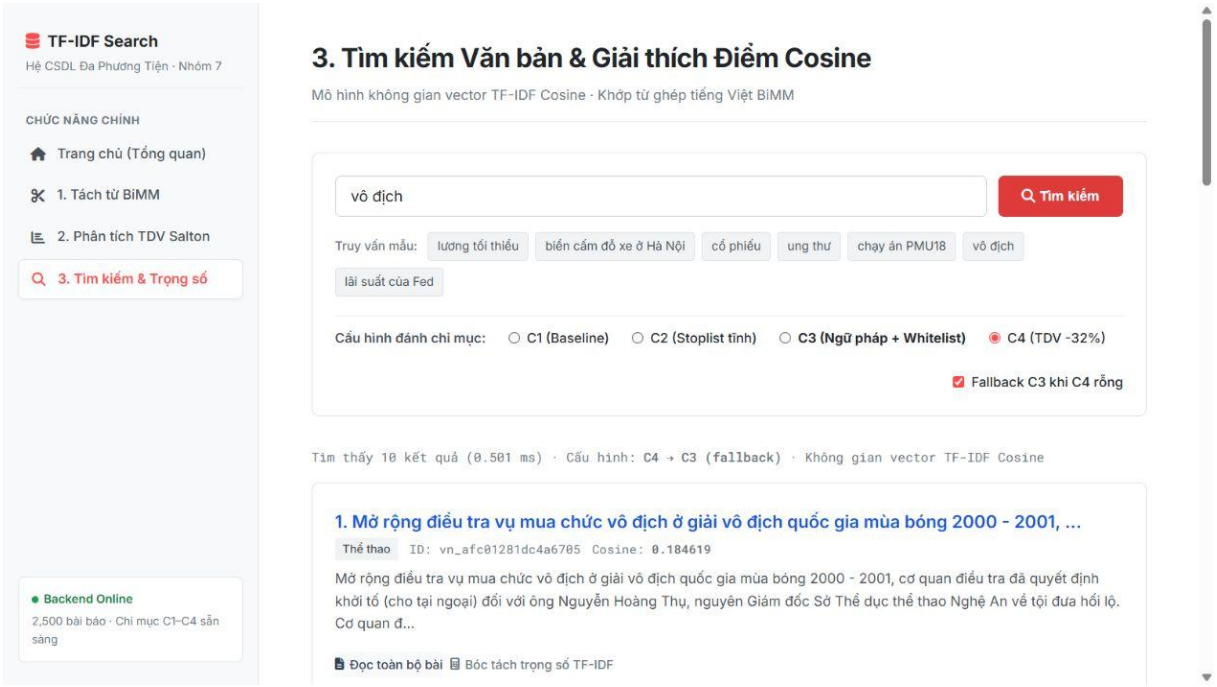


Hình 5.4. Lọc bảy token xuống năm token và giữ từ không

5.6. Cơ chế dự phòng và các trường hợp biên

Với truy vấn "vô địch", C4 thuần không còn thuật ngữ dùng được và trả rỗng. Khi bật Fallback C3 khi C4 rỗng, hệ thống dùng chỉ mục C3 riêng và trả 10 kết quả; phần giải thích cũng sử dụng C3. Cấu hình yêu cầu và cấu hình thực sự sử dụng được phân biệt để người vận hành hiểu kết quả đến từ đâu.

Hình 5.5 cho thấy truy vấn có dữ liệu, lựa chọn fallback và nhãn C4 → C3 cùng các kết quả được trả về.



Hình 5.5. Truy vấn vô địch chuyển từ C4 sang C3 khi bật dự phòng

Bảng 5.2 tổng hợp các kịch bản kiểm tra trên giao diện hoặc thông qua SearchService, gồm đầu vào, cấu hình sử dụng và phản hồi quan sát được.

Bảng 5.2. Kịch bản vận hành và kết quả quan sát

Kịch bản	Đầu vào / cấu hình	Kết quả quan sát
Tìm kiếm thông thường	lương tối thiểu; C3	10 kết quả; đầu bảng có score ≈ 0,206281
C4 không dự phòng	vô địch; C4; fallback tắt	0 kết quả; giao diện không thay bằng bài mẫu
C4 có dự phòng	vô địch; C4; fallback bật	10 kết quả; used_configuration = C3
Query rỗng	Chuỗi rỗng; SearchService C3	Không có kết quả
Ngoài từ vựng	zzzzzzzzzzzzzzzzzzz; C3	Không có kết quả
Giải thích	Query và doc_id của bài đầu	Tổng contributions khớp score
Lọc tầng 1	Câu ở Hình 5.4	7 token → 5; không được giữ

5.7. Thực nghiệm và phân tích kết quả

5.7.1. Chất lượng phân đoạn từ

Tập tham chiếu tách từ gồm 150 câu lấy từ corpus, tương ứng 15 câu mỗi lĩnh vực. Đánh giá dựa trên ranh giới từ (word span): một từ dự đoán chỉ được tính đúng khi cả vị trí bắt đầu và kết thúc trùng với nhãn tham chiếu.

Bảng 5.3 trình bày Precision, Recall và F1 của ba phương pháp trên cùng tập tham chiếu.

Bảng 5.3. Kết quả tách từ theo word span trên 150 câu

Thuật toán	Precision	Recall	Span F1
FMM	0,9511	0,9640	0,9575
BMM	0,9554	0,9684	0,9619
BiMM	0,9554	0,9684	0,9619

BMM và BiMM cùng đạt span F1 = 0,9619; FMM đạt 0,9575. Đối chiếu đầu ra trên 150 câu cho thấy FMM và BMM giống nhau ở 135 câu, khác nhau ở 15 câu. Tuy nhiên, các khóa phân xử gồm tổng số token, số token đơn âm tiết và số token ngoài từ điển đều bằng nhau giữa hai chiều trên cả 150 câu. Quy tắc phá hòa chọn BMM nên BiMM trùng BMM trên toàn bộ tập tham chiếu. Kết quả này chưa cho thấy BiMM cải thiện chất lượng so với BMM trên bộ dữ liệu hiện tại.

Các nhãn tham chiếu bảo toàn thứ tự âm tiết và không ghép qua ranh giới dấu câu. Phụ lục B trình bày một số trường hợp minh họa. Do tập tham chiếu chưa được kiểm tra độc lập toàn bộ, kết quả cần được đánh giá lại khi mở rộng hoặc chuẩn hóa thêm bộ nhãn.

5.7.2. Dung lượng chỉ mục và phân bố TDV

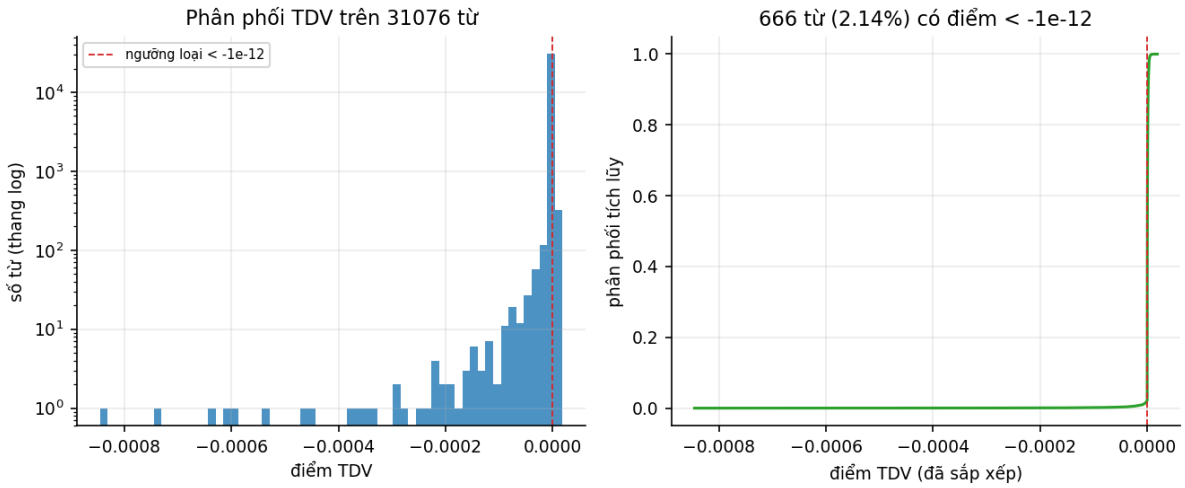
Bảng 5.4 phân biệt chỉ mục C4 thuần với gói C4 cộng C3 khi bật dự phòng.

Bảng 5.4. Dung lượng phục vụ và tệp phân tích của các cấu hình

Cấu hình	Phục vụ (byte)	Phân tích TDV (byte)	Giảm so C1	Mục tiêu 30%
C1	9.621.765	0	0,00%	không đạt
C2	6.987.156	0	27,38%	không đạt
C3	8.748.327	0	9,08%	không đạt
C4	6.542.944	1.834.569	32,00%	đạt
C4 + C3	15.291.271	1.834.569	-58,92%	không đạt

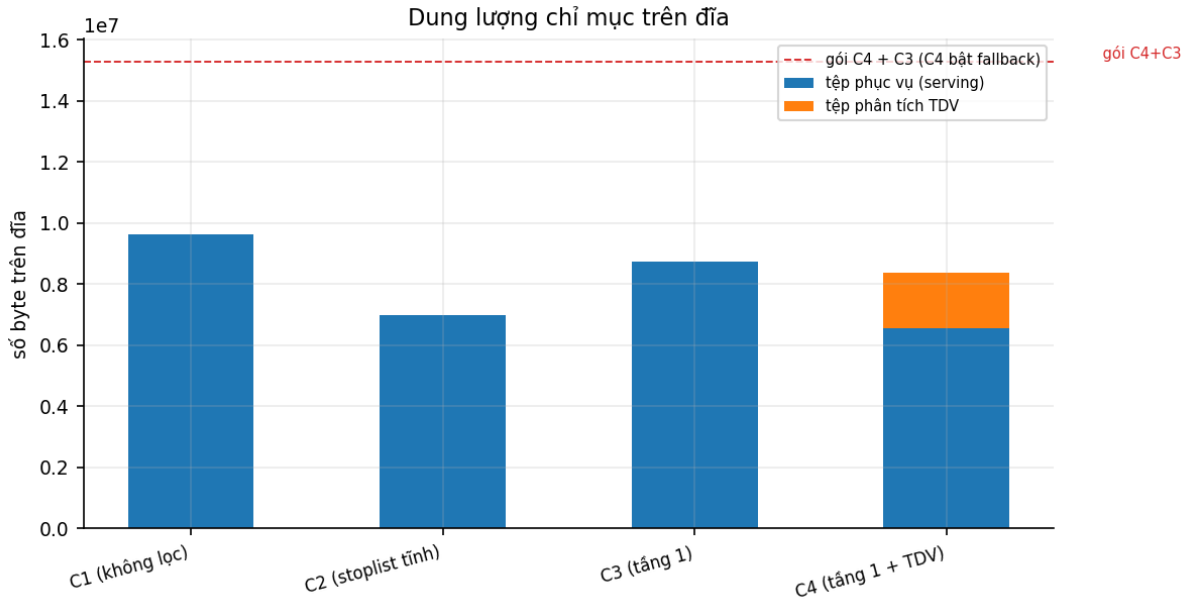
C4 thuần giảm 32,00% dung lượng phục vụ so với C1, đạt mục tiêu giảm ít nhất 30%. Tuy nhiên, triển khai fallback đòi hỏi giữ thêm C3: gói C4+C3 có 15.291.271 byte, tăng 58,92% so với C1. Gói fallback vì vậy không đạt mục tiêu giảm dung lượng. Cột "Mục tiêu 30%" ở Bảng 5.4 chỉ đánh giá tiêu chí dung lượng, không phải kết luận tổng thể về chất lượng hay tính phù hợp của cấu hình. Dung lượng tệp phân tích TDV được thống kê thành hạng mục riêng với dung lượng chỉ mục phục vụ truy vấn.

Hình 5.6 biểu diễn phân bố TDV của 31.076 thuật ngữ; 666 term đạt điều kiện âm trước khi áp dụng guard, còn 589 term thực sự bị loại.



Hình 5.6. Phân bố điểm TDV trên corpus đã khóa

Hình 5.7 trực quan hóa các phạm vi dung lượng đã kê ở Bảng 5.4; đường gói C4+C3 lớn hơn dung lượng C1.



Hình 5.7. Dung lượng phục vụ chỉ mục và gói C4 cộng C3

5.7.3. Độ trễ truy vấn

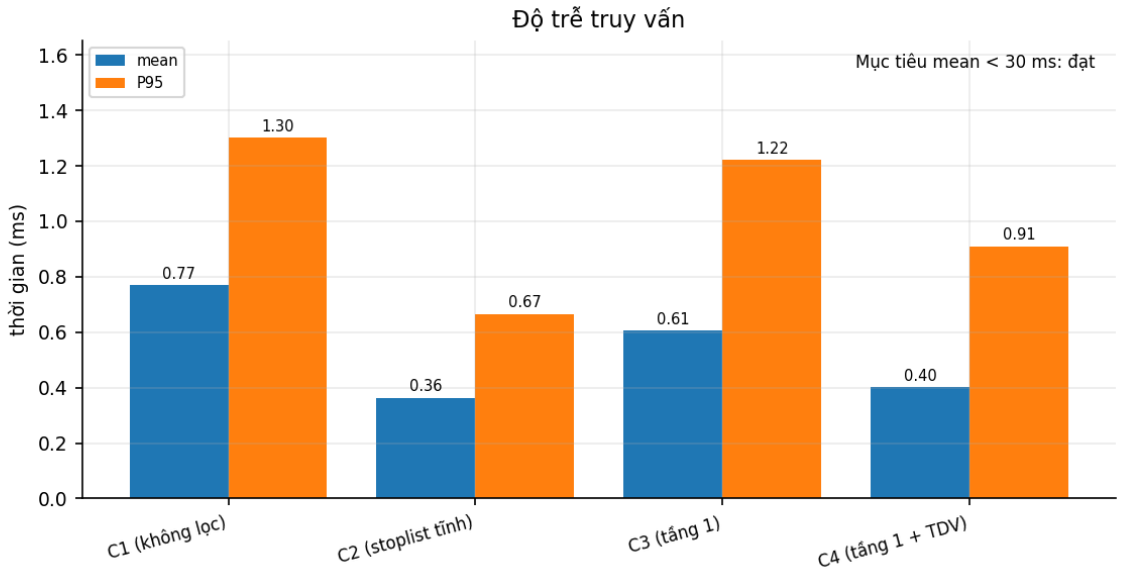
Bảng 5.5 ghi Mean, P95 và số lượt trả rỗng của phép đo 20 truy vấn nhân 100 lần lặp.

Bảng 5.5. Thời gian truy vấn và số lượt trả rỗng

Cấu hình	Lượt đo	Mean (ms)	P95 (ms)	Lượt trả rỗng
C1	2000	0,770	1,302	0
C2	2000	0,363	0,666	0
C3	2000	0,606	1,222	0
C4	2000	0,403	0,910	200
C4 + C3	2000	0,415	0,918	0

Mean của C1–C4 đều dưới mục tiêu 30 ms trên máy và điều kiện đo nêu ở mục 5.1. C4 thuần trả rỗng ở Q04 và Q15, tương ứng 200/2.000 lượt đo; số lượt trả rỗng tương ứng với hai truy vấn, mỗi truy vấn được lặp 100 lần. Fallback sang chỉ mục C3 khôi phục kết quả cho cả hai, mean của phép đo fallback là 0,415 ms. Độ trễ và chất lượng truy xuất được đánh giá bằng các nhóm chỉ số riêng.

Hình 5.8 biểu diễn Mean và P95 từ Bảng 5.5. Phép đo warm process không gồm nạp chỉ mục ban đầu hoặc thời gian vẽ giao diện.



Hình 5.8. Mean và P95 của thời gian truy vấn theo cấu hình

5.7.4. Chất lượng truy xuất và phân tích lĩnh vực

Bảng 5.6 so sánh MAP toàn ranking với P@10, R@10, F1@10 và NDCG@10 trên cùng bộ nhãn.

Bảng 5.6. Chất lượng truy xuất trên 20 truy vấn

Cấu hình	MAP	P@10	R@10	F1@10	NDCG@10
C1	0,7685	0,6200	0,5736	0,5105	0,7917
C2	0,7585	0,6150	0,5687	0,5059	0,7891
C3	0,7689	0,6200	0,5614	0,5076	0,7881
C4	0,6385	0,5150	0,5152	0,4469	0,6809
C4_fallback	0,7202	0,6050	0,5468	0,4934	0,7611

Ghi chú: Các giá trị P@10, R@10, F1@10 và NDCG@10 trong bảng là trung bình macro trên 20 truy vấn. Riêng F1@10 được tính cho từng truy vấn từ Precision và Recall tương ứng, sau đó mới lấy trung bình cộng; không tính bằng cách thay trực tiếp P@10 và R@10 trung bình trong bảng vào công thức F1. Các chỉ số được tổng hợp từ giá trị chưa làm tròn và chỉ làm tròn khi trình bày.

C3 có MAP cao nhất (0,7689), gần với C1 (0,7685); C2 đạt 0,7585. C4 thuần đạt 0,6385; fallback đạt 0,7202, vẫn thấp hơn C3. Kết quả cho thấy giảm chiều bằng TDV có thể làm mất tín hiệu cần cho một số truy vấn. Chênh lệch giữa C1 và C3 chưa được kiểm định ý nghĩa thống kê; thứ hạng các cấu hình phản ánh kết quả trên corpus và tập truy vấn hiện hành.

Đối chiếu kết quả Top-10 với qrels cho thấy C1, C2 và C3 đều có nhãn cho 200/200 kết quả trả về. C4 có 9/180 kết quả chưa được chấm, thuộc Q02, Q09, Q19 và Q20; 20 vị trí còn thiếu so với mức tối đa 200 là do Q04 và Q15 trả rỗng, không được tính là tài liệu chưa chấm. Pool chứa Top-20 của baseline TF-IDF không lọc từ dừng nên bao phủ đầy đủ phần đầu xếp hạng C1, còn C4 có thể đưa lên các tài liệu ngoài pool. Khác biệt này tạo nguy cơ thiên lệch khi so sánh; cần chấm bổ sung để xác định ảnh hưởng, chưa thể quy mức giảm MAP của C4 cho pooling.

C2 giảm 27,38% dung lượng, có Mean thấp nhất trong lần đo (0,363 ms) và MAP thấp hơn C1 khoảng 0,0100 điểm. Vì vậy, C2 là phương án đáng cân nhắc khi ưu tiên dung lượng và độ trễ, dù chưa đạt ngưỡng giảm 30%. Khi ưu tiên chất lượng trên bộ nhãn hiện tại, C1 và C3 là hai lựa chọn phù hợp hơn C4 thuần. IDF đã giảm tương đối ảnh hưởng của thuật ngữ phổ biến [1], nên lọc thêm từ dừng không nhất thiết làm tăng chất lượng; đây là một khả năng giải thích, chưa phải nguyên nhân được tách riêng bằng thực nghiệm.

Bảng 5.7 trình bày MAP theo lĩnh vực. Mỗi lĩnh vực có hai truy vấn nên các điểm nhóm chỉ phản ánh kết quả trên mẫu thực nghiệm, chưa đủ đại diện cho toàn bộ lĩnh vực.

Bảng 5.7. MAP theo lĩnh vực và cấu hình truy xuất

Lĩnh vực	MAP C1	MAP C3	MAP C4	MAP fallback
Chính trị – Xã hội	0,779	0,779	0,748	0,748
Khoa học	0,795	0,797	0,756	0,756

Kinh doanh	0,920	0,930	0,917	0,917
Pháp luật	0,626	0,623	0,551	0,551
Sức khỏe	0,735	0,735	0,676	0,676
Thế giới	0,759	0,755	0,784	0,784
Thể thao	0,825	0,826	0,385	0,824
Vi tính	0,608	0,612	0,408	0,408
Văn hóa	0,837	0,829	0,780	0,780
Đời sống	0,801	0,803	0,380	0,758

Hai truy vấn C4 trả rỗng thuộc Đời sống và Thể thao; fallback sử dụng C3 riêng để khôi phục. Chi phí triển khai fallback được đánh giá theo dung lượng gói C4+C3 cùng các chỉ số chất lượng tương ứng.

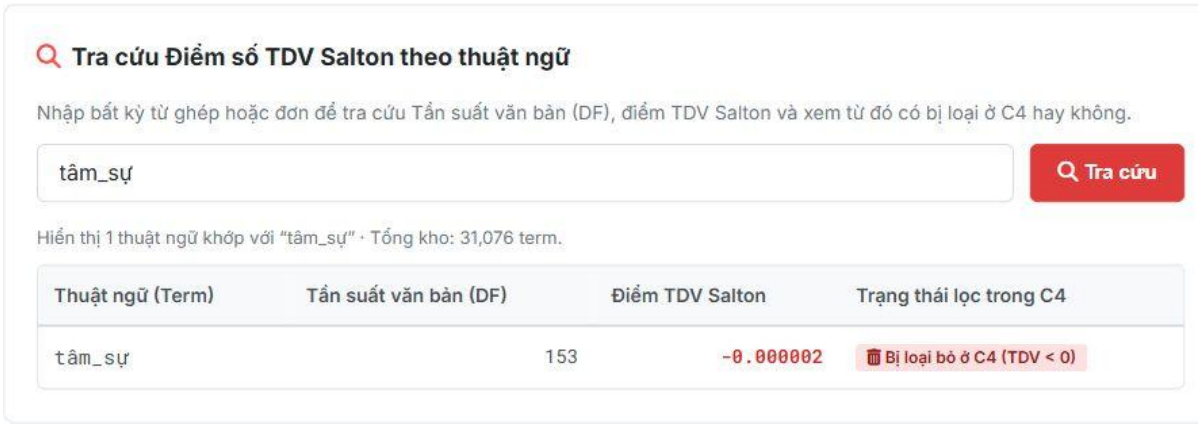
Bảng 5.8 trình bày điểm TDV và tần suất tài liệu (df) của các thuật ngữ trong Q04 "tâm sự gia đình" và Q15 "vô địch". Các giá trị được trích từ bảng phân tích của chỉ mục C4 trên corpus 2.500 bài; df là số tài liệu chứa thuật ngữ sau tiền xử lý và lọc tầng 1, không phải tổng số lần xuất hiện.

Bảng 5.8. Giá trị TDV và tần suất tài liệu của các thuật ngữ trong Q04 và Q15

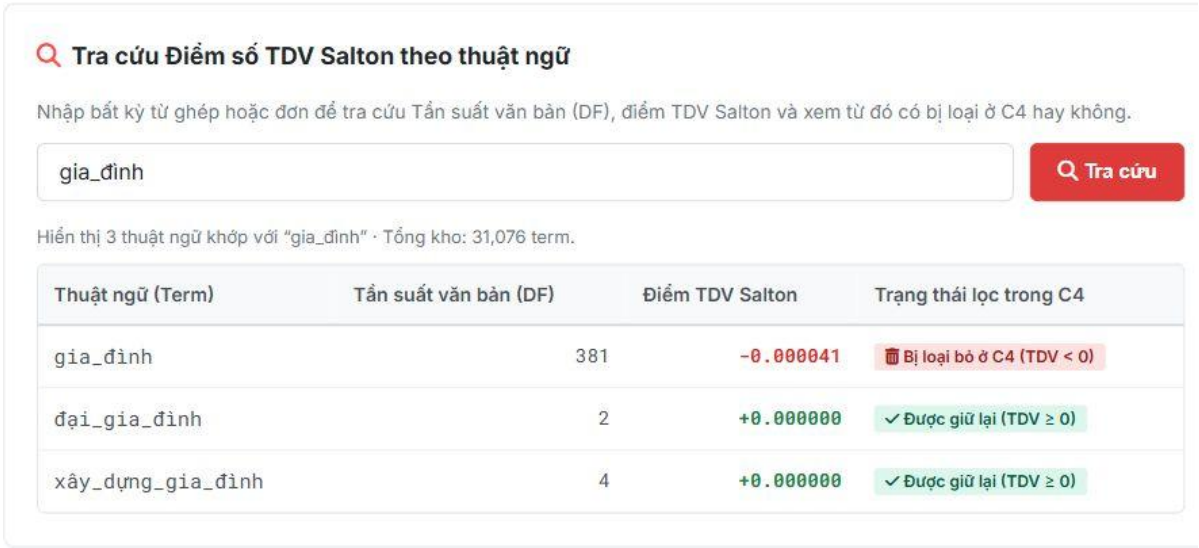
Truy vấn	Thuật ngữ	df	TDV	Trạng thái tại C4
Q04	tâm_sự	153	$-1{,}561750 \times 10^{-6}$	Bị loại ở tầng 2
Q04	gia_đình	381	$-4{,}081652 \times 10^{-5}$	Bị loại ở tầng 2
Q15	vô_địch	127	$-1{,}273914 \times 10^{-6}$	Bị loại ở tầng 2

Cả ba thuật ngữ đều có TDV nhỏ hơn -10^{-12} và thuộc stoplist tầng 2. Q04 còn hai token tâm_sự, gia_đình sau tầng 1; Q15 còn token vô_địch. Khi chuyển sang C4, toàn bộ các token này bị loại khỏi không gian truy vấn nên cả hai truy vấn trả rỗng. Các thuật ngữ vẫn có trong corpus và chỉ mục C3; bật dự phòng sang C3 trả 10 kết quả cho mỗi truy vấn với Top-K = 10. Trường hợp này cho thấy tiêu chí hình học trên toàn corpus có thể loại một thuật ngữ vẫn quan trọng đối với truy vấn cụ thể.

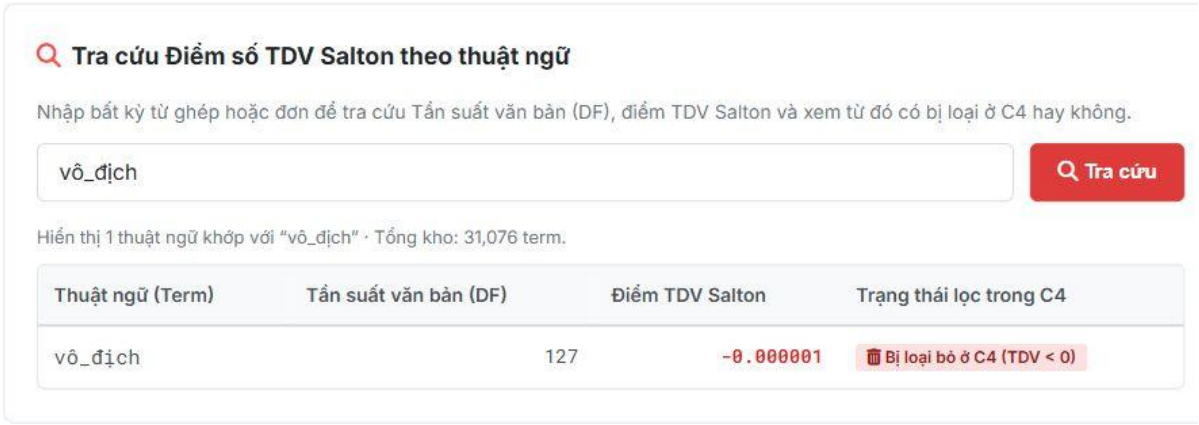
Hình 5.9 ghi lại vùng tra cứu của chức năng "Phân tích TDV Salton" khi backend đang hoạt động: (a) tâm_sự, (b) gia_đình và (c) vô_địch. Giao diện tìm theo chuỗi con nên ảnh (b) còn hiển thị các thuật ngữ chứa gia_đình; dòng gia_đình là kết quả được dùng trong Bảng 5.8. Điểm trên giao diện được làm tròn sáu chữ số sau dấu thập phân; Bảng 5.8 dùng dạng khoa học để giữ độ chính xác.



(a) Tra cứu tâm_sự



(b) Tra cứu gia_đình



(c) Tra cứu vô_địch

Hình 5.9. Tra cứu TDV của các thuật ngữ trong Q04 và Q15

5.7.5. Đối chứng cấu trúc tra cứu

Phép so sánh Trie–Set sử dụng cùng từ điển, đầu vào, cửa sổ và luật BiMM; 750 lượt đối soát (250 văn bản × 3 phương pháp) cho kết quả token giống nhau. Bảng 5.9 trình bày thời gian tách từ BiMM trên mẫu 150 câu và 100 bài đầu của corpus. Số liệu được trích từ results/lookup/trie_vs_set.csv. Mỗi văn bản được đo 10 vòng sau 2 lượt warm-up; thứ tự Trie/Set được xen kẽ và đảo qua các vòng.

Bảng 5.9. Thời gian tách từ BiMM bằng Trie và hash set

Đầu vào, BiMM	Trie: Mean (ms/văn bản)	Set: Mean (ms/văn bản)	Trie/Set
150 câu tham chiếu	0,4557	0,1958	2,33 lần
100 bài đầu corpus	6,5355	2,6611	2,46 lần

Trên hai tập đầu vào ở Bảng 5.9, Trie chậm hơn Set lần lượt khoảng 2,33 và 2,46 lần. Bản hiện thực hiện tại tra lại từ gốc cho mỗi độ dài ứng viên nên chưa tận dụng đầy đủ khả năng dùng chung tiền tố. Đây là hạn chế hiệu năng của cách cài đặt, không phải khác biệt về kết quả tách từ. Khi tối ưu cần bảo toàn đầu ra rồi đo lại; các thời gian trong bảng là thời gian tách từ, không so trực tiếp với độ trễ truy xuất ở Bảng 5.5.

5.7.6. Kiểm tra tính nhất quán và phạm vi đánh giá

Bốn chỉ mục được dựng trên cùng corpus và quy trình tiền xử lý. Đánh giá truy xuất sử dụng 20 truy vấn với độ sâu xếp hạng tối đa 2.500; đánh giá tách từ sử dụng 150 câu; độ trễ được đo qua 2.000 lượt cho mỗi cấu hình. Trên 780 cặp truy vấn–kết quả, tổng đóng góp của các thuật ngữ khớp điểm Cosine với sai số lớn nhất $5{,}55 \times 10^{-17}$. Tám trường hợp truy vấn rỗng hoặc ngoài từ vựng đều trả danh sách rỗng. Những kiểm tra này xác nhận tính nhất quán của phép tính và xử lý trường hợp biên; độ tin cậy ngữ nghĩa vẫn phụ thuộc chất lượng và phạm vi của bộ nhãn.

CHƯƠNG 6. KẾT LUẬN VÀ HƯỚNG PHÁT TRIỂN

6.1. Kết quả đạt được

Nhóm đã hiện thực các giải thuật tách từ FMM, BMM và BiMM trên cấu trúc Trie với từ điển Viet74K đã làm sạch. BiMM đạt span F1 = 0,9619 trên 150 câu tham chiếu. Kết quả này được xem xét trong phạm vi và giới hạn của nguồn gold đã trình bày ở Chương 5.

Hệ thống sử dụng trọng số TF-IDF, chỉ mục đảo và độ tương đồng Cosine để truy xuất tài liệu, đồng thời giải thích đóng góp của từng thuật ngữ vào điểm xếp hạng. Độ trễ trung bình của các cấu hình C1–C4 nằm trong khoảng 0,363–0,770 ms trên máy đo đã nêu. Giải thuật TDV thực hiện chuẩn hóa lại vector sau khi thử bỏ chiều, giữ cố định IDF sơ bộ và có cách tính tham chiếu để đối soát. Chỉ mục C4 thuần giảm 32,00% dung lượng phục vụ so với C1.

Quy trình đánh giá sử dụng 20 truy vấn, 669 cặp truy vấn–tài liệu và 150 câu tham chiếu tách từ để so sánh các cấu hình theo chất lượng, độ trễ và dung lượng. Các kiểm tra đã xác nhận tính nhất quán giữa điểm Cosine và tổng đóng góp thuật ngữ, đồng thời kiểm tra cách xử lý truy vấn rỗng và ngoài từ vựng. Các chức năng được minh họa bằng ảnh chụp vận hành có dữ liệu trong Chương 5.

Trên bộ dữ liệu hiện tại, nhóm khuyến nghị cân nhắc C1/C3 khi ưu tiên chất lượng và C2 khi ưu tiên dung lượng, độ trễ với mức giảm MAP nhỏ. C3 có MAP cao nhất nhưng chênh lệch với C1 chưa được kiểm định ý nghĩa thống kê. C4 thuần chỉ phù hợp khi chấp nhận đánh đổi chất lượng và khả năng trả rỗng để đạt mục tiêu dung lượng; nếu bật fallback, chi phí lưu trữ được tính cho cả C4 và C3.

6.2. Hạn chế

Tập nhãn liên quan được xây dựng bằng pooling nên chưa bao phủ toàn bộ tài liệu liên quan trong corpus. C4 có kết quả Top-10 chưa được chấm, trong khi toàn bộ Top-10 của C1–C3 đã có nhãn; mức ảnh hưởng của khác biệt này đến so sánh chất lượng chưa được xác định. Bộ đánh giá chỉ có 20 truy vấn, hai truy vấn mỗi lĩnh vực. Bộ nhãn liên quan và tập tham chiếu tách từ cũng chưa trải qua một vòng chấm độc lập toàn bộ.

Các số đo độ trễ phản ánh cấu hình phần cứng và điều kiện thực nghiệm đã sử dụng. Bản hiện thực Trie có độ trễ cao hơn hash set khoảng 2–2,5 lần do lặp lại thao tác tra từ gốc, hạn chế hiệu năng khi mở rộng quy mô. C4 thuần có hai truy vấn rỗng và MAP thấp hơn C1/C3 trong thí nghiệm này. Cơ chế fallback cần giữ chỉ mục C3 đi kèm, làm tổng dung lượng tăng gần 59% so với C1.

Thí nghiệm chưa đối chứng truy xuất ở mức âm tiết với tách từ, cũng chưa tách riêng tác động của việc bật/tắt guard. Do đó, span F1 phản ánh chất lượng phân đoạn; kiểm thử guard phản ánh việc bảo toàn token theo quy tắc. Hai loại kết quả này chưa xác định mức đóng góp riêng của tách từ và guard vào MAP hoặc NDCG, cũng chưa chứng minh hệ thống hiểu đầy đủ ý nghĩa phủ định.

6.3. Hướng phát triển

Đánh giá có thể được mở rộng bằng cách chấm bổ sung các kết quả chưa có nhãn trong hợp Top-K của các cấu hình và tổ chức hai người chấm độc lập, đo độ đồng thuận, phân xử bất đồng rồi đánh giá lại. Tập gold tách từ cần được kiểm tra thêm. Về hiệu năng, hướng cải tiến Trie là thực hiện một lượt dò tiền tố từ mỗi vị trí, bảo toàn ranh giới đoạn, vết xử lý và quy tắc chọn; tính tương đương đầu ra được kiểm tra trước khi đo lại với hash set.

Các đối chứng tiếp theo gồm mức âm tiết so với tách từ BiMM và bật so với tắt guard trên cùng quy trình. Nhóm cũng định hướng thử chính sách chọn từ dừng theo truy vấn hoặc lĩnh vực, đo riêng chất lượng và chi phí triển khai. BM25 có thể được đưa vào so sánh chính thức với TF-IDF, kết hợp khảo sát các phương án xếp hạng và mở rộng dữ liệu sau khi xác minh quyền sử dụng, phân phối.

TÀI LIỆU THAM KHẢO

[1] Manning, C. D.; Raghavan, P.; Schütze, H. (2008). Introduction to Information Retrieval. Cambridge University Press. Bản trực tuyến: https://nlp.stanford.edu/IR-book/ (truy cập ngày 19/10/2026).

[2] Lê Hồng Phương; Nguyễn Thị Minh Huyền; Roussanaly, A.; Hồ Tường Vinh (2008). A Hybrid Approach to Word Segmentation of Vietnamese Texts. Trong: Language and Automata Theory and Applications (LATA 2008), Lecture Notes in Computer Science, tập 5196, tr. 240–249. Springer. DOI: 10.1007/978-3-540-88282-4_23.

[3] stopwords. Vietnamese stopwords. Tệp vietnamese-stopwords.txt, phiên bản a453d389e1b52e20748ca83ddd8b0faebb04f5aa. Giấy phép MIT; bản quyền Van-Duyet Le. https://github.com/stopwords/vietnamese-stopwords (truy cập ngày 19/10/2026).

[4] scikit-learn developers. TfidfVectorizer. Tài liệu scikit-learn 1.8.0. https://scikit-learn.org/1.8/modules/generated/sklearn.feature_extraction.text.TfidfVectorizer.html (truy cập ngày 19/10/2026).

[5] Salton, G.; Wong, A.; Yang, C. S. (1975). A Vector Space Model for Automatic Indexing. Communications of the ACM, 18(11), tr. 613–620. DOI: 10.1145/361219.361220.

[6] Salton, G.; Yang, C. S.; Yu, C. T. (1975). A Theory of Term Importance in Automatic Text Analysis. Journal of the American Society for Information Science, 26(1), tr. 33–44. DOI: 10.1002/asi.4630260106.

[7] NumPy developers. The N-dimensional array (ndarray). NumPy v2.4 Manual. https://numpy.org/doc/2.4/reference/arrays.ndarray.html (truy cập ngày 19/10/2026).

[8] The SciPy community. scipy.sparse.csr_matrix. SciPy v1.17.0 Manual. https://docs.scipy.org/doc/scipy-1.17.0/reference/generated/scipy.sparse.csr_matrix.html (truy cập ngày 19/10/2026).

[9] duyet (Van-Duyet Le, duy trì kho phân phối). Vietnamese wordlist – Viet74K. Nguồn gốc: Ho Ngoc Duc. Phiên bản 688b0953c8cdb21ee090ce80b83cefdb052fe2cd. Giấy phép GPL-2.0. https://github.com/duyet/vietnamese-wordlist (truy cập ngày 19/10/2026).

[10] duyvuleo (kho phân phối). VNTC – A Large-scale Vietnamese News Text Classification Corpus. Bộ dữ liệu 10 chủ đề, phiên bản 10Topics/Ver1.1, phần Train_Full; thống kê và nguồn báo theo Stats.txt. https://github.com/duyvuleo/VNTC/tree/master/Data/10Topics/Ver1.1 (truy cập ngày 19/10/2026).

PHỤ LỤC A. MỘT SỐ TRƯỜNG HỢP GÁN NHÃN LIÊN QUAN

Phụ lục này minh họa việc xác định mức liên quan giữa truy vấn và tài liệu. Mức nhãn được quyết định theo nội dung bài viết và mức độ đáp ứng nhu cầu truy vấn; việc trùng lĩnh vực hoặc xuất hiện một từ khóa riêng lẻ không tự quyết định mức liên quan.

Bảng A.1 trình bày tám trường hợp tiêu biểu trong tập nhãn liên quan dùng cho thực nghiệm.

Bảng A.1. Một số trường hợp gán nhãn liên quan

Truy vấn / mã tài liệu	**Mức liên quan**	**Cơ sở đánh giá**
Q03 / vn_706ae3e191d963a8	1	Nội dung gần với chủ đề tha thứ sau ngoại tình, nhưng là lời khuyên cho người vợ trước sự phản bội của chồng, chưa đáp ứng trực tiếp tình huống truy vấn.
Q04 / vn_10288e4d8ae0d55b	2	Bài viết trực tiếp chia sẻ và tư vấn về mâu thuẫn hôn nhân, quan hệ vợ chồng và gia đình.
Q08 / vn_a51c84de855dc95c	0	Không bàn về lãi suất cơ bản hoặc chính sách tiền tệ của Fed.
Q10 / vn_a7ab1dbd1332334b	2	Nội dung trực tiếp đề cập đường dây chạy án trong vụ PMU18.
Q16 / vn_cbe182ef26813cda	0	Nội dung đề cập việc đặt vé, chưa cung cấp thông tin về các trận chung kết như yêu cầu truy vấn.
Q18 / vn_161f379098b8499f	2	Bài viết mô tả liveshow “Nắng lên”, các ca khúc và phần biểu diễn của Thanh Lam.
Q19 / vn_dfcce0e16a08fae9	1	Phần hồi âm hướng dẫn kiểm tra virus, dùng antivirus và cập nhật Windows, nhưng không đề cập đánh cắp mật khẩu.
Q20 / vn_2a683b464546fcd2	0	Nội dung không đáp ứng yêu cầu về dịch vụ phần mềm và thông tin di động trong truy vấn.

Mức 0 biểu thị không liên quan; mức 1 biểu thị liên quan một phần; mức 2 biểu thị đáp ứng trực tiếp truy vấn. Các chỉ số nhị phân xem mức 1 và 2 là liên quan; NDCG sử dụng đầy đủ ba mức nhãn.

PHỤ LỤC B. MỘT SỐ TRƯỜNG HỢP PHÂN ĐOẠN TỪ

Phụ lục này trình bày một số trích đoạn và cách phân đoạn trong tập tham chiếu. Các phân đoạn tham chiếu bảo toàn thứ tự âm tiết của câu nguồn và tuân thủ ranh giới dấu câu.

Bảng B.1 minh họa cách xử lý từ ghép, hư từ và cụm từ theo quy ước của tập tham chiếu.

Bảng B.1. Một số trường hợp phân đoạn từ trong tập tham chiếu

Mã câu	**Trích đoạn**	**Phân đoạn tham chiếu**	**Nhận xét**
SG010	độc đáo để	độc_đáo để	Từ ghép “độc đáo” được giữ; “để” là token riêng.
SG053	điều tra của cơ quan công an	điều_tra của cơ_quan công_an	Tách hư từ “của” khỏi các từ ghép.
SG089	nhiệm kỳ hai sáu năm	nhiệm_kỳ hai sáu_năm	Giữ ranh giới từ theo quy ước của tập tham chiếu.

PHỤ LỤC C. DANH MỤC 20 TRUY VẤN

Bảng C.1 liệt kê các truy vấn được giữ nguyên nội dung trong mọi cấu hình.

Bảng C.1. Danh mục 20 truy vấn đánh giá

ID	Lĩnh vực	Nội dung truy vấn
Q01	Chính trị – Xã hội	lương tối thiểu
Q02	Chính trị – Xã hội	biển cấm đỗ xe ô tô ở Hà Nội mất hiệu lực thì người dân đỗ xe ở đâu
Q03	Đời sống	có nên tha thứ cho người vợ ngoại tình
Q04	Đời sống	tâm sự gia đình
Q05	Khoa học	nghiên cứu lõi băng để khám phá quy luật biến đổi khí hậu
Q06	Khoa học	Trung Quốc xây trạm không gian và Nga phóng tàu lên ISS khác nhau như thế nào
Q07	Kinh doanh	cổ phiếu
Q08	Kinh doanh	lãi suất cơ bản và chính sách tiền tệ của Fed ảnh hưởng thị trường ra sao
Q09	Pháp luật	điều tra vụ biển thủ hơn 8,7 tỷ đồng cá độ bóng đá đã được xử lý ra sao
Q10	Pháp luật	đường dây chạy án trong vụ PMU18
Q11	Sức khỏe	ung thư
Q12	Sức khỏe	mỡ máu cao nếu không điều trị có thể gây những biến chứng gì
Q13	Thế giới	vì sao Mỹ vẫn chưa tìm thấy vũ khí cấm ở Iraq
Q14	Thế giới	xác nhận danh tính hài cốt lính Mỹ mất tích trong Chiến tranh Triều Tiên
Q15	Thể thao	vô địch
Q16	Thể thao	Việt Nam đăng cai một vòng bảng Tiger Cup 2004 và các trận chung kết diễn ra thế nào
Q17	Văn hóa	cảnh nóng và trang phục hở trong phim truyền hình Việt Nam gây tranh luận như thế nào
Q18	Văn hóa	ca khúc và chương trình biểu diễn âm nhạc của nghệ sĩ
Q19	Vi tính	virus máy tính đánh cắp mật khẩu Windows và cách phòng tránh
Q20	Vi tính	dịch vụ phần mềm và thông tin di động được doanh nghiệp cung cấp cho khách hàng ra sao

Các truy vấn ở Bảng C.1 được sử dụng thống nhất cho mọi cấu hình. Nhãn liên quan 0/1/2 được xác định riêng cho từng cặp truy vấn–tài liệu; kết quả so sánh được trình bày tại Bảng 5.6 và Bảng 5.7.